ĐẠI HỌC QUỐC GIA TPHCM

TRƯỜNG ĐẠI HỌC KHOA HỌC TỰ NHIÊN

KHOA CÔNG NGHỆ THÔNG TIN

Báo cáo LAB 3

Project: Phân cụm và ứng dụng
Paper: Automatic Data Curation for Self-Supervised Learning: A Clustering-Based Approach

Môn học: Khai thác dữ liệu và ứng dụng

Sinh viên thực hiện:

Lê Quốc Thiện (23127481)

Phạm Quang Thịnh (23127485)

Giảng viên hướng dẫn:

GS.TS. Lê Hoài Bắc

ThS. Nguyễn Ngọc Đức

ThS. Lê Nhựt Nam

Ngày 27 tháng 4 năm 2026

Mục lục

Tóm tắt nội dung **1**

1 Bối cảnh và động lực nghiên cứu **2**

1.1 Vấn đề cần giải quyết 2

1.2 Tầm quan trọng và ví dụ minh họa 2

1.3 Các phương pháp trước đây 3

1.4 Đóng góp chính của bài báo 5

2 Phương pháp đề xuất **6**

2.1 Ký hiệu và bài toán 6

2.2 Kiến trúc và pipeline 7

2.3 Các thành phần kỹ thuật 9

2.4 Tính chất lý thuyết 9

2.5 Độ phức tạp 11

3 Phân tích phê bình **11**

3.1 Điểm mạnh 11

3.2 Hạn chế 13

3.3 Giả định ngầm 14

3.4 Hướng phát triển 14

4 Tái hiện thực nghiệm **15**

4.1 Thực nghiệm trên dữ liệu mô phỏng (Synthetic Data 2D) 15

4.1.1 Thiết lập dữ liệu và tham số thực nghiệm 15

4.1.2 Phân tích kết quả tái thực nghiệm trên dữ liệu mô phỏng 2D 16

4.2 Đối chứng thực nghiệm với mã nguồn gốc và phân tích Insight (Validation) 19

4.2.1 Đảm bảo tính tái hiện: 19

4.2.2 Phân tích sai lệch và Insight: 21

4.2.3 Phân tích hiệu năng thời gian thực thi (Execution Time Efficiency) 21

4.2.4 Đối chứng với mã nguồn gốc của tác giả 22

4.2.5 Kết luận: 23
4.3 Giới hạn thực nghiệm và rào cản tài nguyên 23

5 Thiết lập bài toán trên bộ dữ liệu mới (CIFAR-10) 24
5.1 Xây dựng phân phối Long-Tail 24
5.2 Pipeline thực nghiệm 26
5.3 Thực nghiệm đánh giá trên dữ liệu CIFAR-10 Long-tail 28
5.3.1 Cấu hình thực nghiệm (Experimental Setup) 28
5.3.2 Đánh giá chất lượng phân cụm ngữ nghĩa 29
5.3.3 Đánh giá hiệu năng bài toán phân loại (Data Curation) 30
5.3.4 Kết luận thực nghiệm CIFAR-10 31
5.4 Thiết lập thực nghiệm kiểm định logic thuật toán cài đặt so với của tác giả 31
5.4.1 Các cấu hình thực nghiệm 31
5.4.2 Phân tích kết quả đối chiếu với tác giả 32

6 Ablation study 34
6.1 Ablation Study 1: Chiến lược chọn mẫu từ tâm cụm 34
6.2 Ablation Study 2: Ảnh hưởng của Resampling Budget (r_t) 35

7 Kết luận và bài học 36
7.1 Sự đánh đổi giữa chất lượng, số lượng và tính đa dạng 36
7.2 Thách thức về tài nguyên và rào cản tái hiện quy mô lớn 36
7.3 Chiến lược thực nghiệm thay thế và Bài học về tư duy nghiên cứu 37

Tài liệu tham khảo 38

Phụ lục 38

Tóm tắt nội dung

Trong bối cảnh học máy hiện đại, hiệu năng của các mô hình học tự giám sát (Self-Supervised Learning - SSL) phụ thuộc chặt chẽ vào chất lượng và phân phối của dữ liệu huấn luyện, vốn thường gặp thách thức bởi đặc điểm đuôi dài (long-tail) và mất cân bằng nghiêm trọng của dữ liệu thô từ Internet. Bài toán đặt ra là thiết lập một quy trình tuyển lọc dữ liệu tự động (Automatic Data Curation) nhằm tối ưu hóa biểu diễn không gian khái niệm mà không cần đến nhãn thủ công. Xuất phát từ động lực đó, nghiên cứu này tập trung thực nghiệm và đánh giá phương pháp phân cụm k-means phân cấp (Hierarchical k-means) kết hợp kỹ thuật lấy mẫu lại (resampling) để làm phẳng mật độ phân phối của các tâm cụm về phía phân phối đều, một giải pháp đã được chứng minh về mặt lý thuyết thông qua việc giảm thiểu phân biệt Kullback-Leibler (KLD) trong dữ liệu mô phỏng 2D. Nhóm đã tiến hành tái hiện thực nghiệm trên dữ liệu mô phỏng 2D để kiểm chứng khả năng "làm phẳng" phân phối và triển khai hệ thống trên bộ dữ liệu CIFAR-10 được cấu hình theo dạng đuôi dài bằng cách sử dụng đặc trưng nhúng từ mô hình DINOv2. Qua quá trình tái thực nghiệm, kết quả thực nghiệm cho thấy phương pháp đề xuất vượt trội hơn hẳn các kỹ thuật truyền thống như DBSCAN hay Agglomerative Clustering về độ ổn định và cấu trúc ngữ nghĩa của các cụm, đồng thời đạt được chỉ số KLD tiệm cận mức tối ưu. Đồng thời, nhóm rút ra bài học quan trọng về sự đánh đổi giữa số lượng và chất lượng dữ liệu, khẳng định rằng việc tối ưu hóa mật độ thông tin thông qua chiến lược lấy mẫu thông minh đóng vai trò then chốt trong việc cải thiện độ bền vững của mô hình, mặc dù vẫn tồn tại những rào cản đáng kể về tài nguyên tính toán khi triển khai ở quy mô lớn.

1 Bối cảnh và động lực nghiên cứu

1.1 Vấn đề cần giải quyết

Self-supervised learning (SSL) đã trở thành nền tảng của nhiều hệ thống học máy hiện đại, cho phép huấn luyện các mô hình lớn mà không cần nhãn thủ công. Tuy nhiên, chất lượng và phân bố dữ liệu huấn luyện tác động mạnh đến chất lượng kết quả thu được, dẫn đến các thách thức cụ thể sau:

- **Đặc điểm dữ liệu Internet**: Các tập dữ liệu Internet thô thường phân bố theo quy luật *đuôi dài* (long-tail), trong đó một vài khái niệm (ví dụ: "chó", "trang web") xuất hiện quá nhiều, trong khi nhiều khái niệm khác (ví dụ: "plunger") lại xuất hiện rất ít.
- **Hạn chế về độ bao phủ**: Mô hình SSL học tập chủ yếu từ các khái niệm chiếm ưu thế mà bỏ qua các khái niệm hiếm, dẫn đến khả năng bao phủ khái niệm bị hạn chế nghiêm trọng.
- **Thiên vị biểu diễn**: Xu hướng phân lớp và biểu diễn sẽ bị thiên vị về phía các lớp phổ biến ("đầu đuôi"), làm suy giảm hiệu năng khi đối mặt với các nhiệm vụ nhận diện khó hoặc các trường hợp ngoại lệ (outliers).

Minh chứng thực nghiệm: Trong bài báo, khi tạo ra các phiên bản mất cân bằng của ImageNet với yếu tố mất cân bằng tăng dần, kết quả cho thấy độ chính xác phân loại tuyến tính của mô hình sụt giảm mạnh từ **82.7%** xuống chỉ còn **57.0%**.

Imbalance factor α	0.0	0.5	1.0	2.0
Accuracy (%)	**82.7**	79.0	74.2	**57.0**

Câu hỏi đặt ra: Làm thế nào để xây dựng các tập dữ liệu lớn, đa dạng nhưng vẫn đảm bảo tính **cân bằng**, nhằm hỗ trợ SSL đạt được biểu diễn tốt nhất trên toàn bộ không gian khái niệm.

1.2 Tầm quan trọng và ví dụ minh họa

Vấn đề này rất thực tế trong bối cảnh hiện nay khi các mô hình quy mô lớn đòi hỏi hàng tỷ token hay hàng triệu ảnh để huấn luyện. Tầm quan trọng của việc cân bằng dữ liệu được thể hiện qua các khía cạnh sau:

- **Mô hình ngôn ngữ lớn (LLM)**: Các mô hình này thường được huấn luyện trên các kho dữ liệu được tuyển lọc cẩn thận như Wikipedia để đảm bảo tính nhất quán về ngôn ngữ và chủ đề.

- **Mô hình ảnh nền tảng**: Điển hình như DINOv2 (Oquab et al., 2023), thường sử dụng ảnh lấy từ bộ dữ liệu đã đánh dấu nhãn trước đó để đảm bảo cân bằng giữa các khái niệm.

- **Hệ quả của dữ liệu Internet thô**: Ngược lại, nếu huấn luyện trên dữ liệu Internet thô (ngẫu nhiên), kết quả thực nghiệm cho thấy hiệu năng suy giảm đáng kể trên các bộ kiểm thử tiêu chuẩn. Các thử nghiệm của tác giả minh họa rằng các tập dữ liệu bị "long tail" đều cho chất lượng biểu diễn kém hơn so với các tập đã cân bằng.

- **Lĩnh vực y tế và giám sát môi trường**: Trong các nhiệm vụ liên quan đến y tế (ảnh y tế) hay giám sát môi trường (ảnh vệ tinh), chất lượng tập dữ liệu huấn luyện càng quan trọng vì dữ liệu chuẩn thường rất hạn chế.

- **Ví dụ về ước lượng chiều cao tán cây**: Tác giả trích dẫn công trình của Tolan et al. (2023) về ước lượng chiều cao tán cây từ ảnh vệ tinh. Kết quả cho thấy nếu sử dụng mô hình nền được huấn luyện trên dữ liệu ảnh vệ tinh cân bằng thì sai số trung bình (MAE) giảm và hệ số R^2 tăng đáng kể so với việc sử dụng mô hình huấn luyện trên dữ liệu thô.

Những ví dụ này cho thấy việc xây dựng dữ liệu huấn luyện lớn nhưng cân bằng sẽ giúp mô hình SSL học được các đặc trưng tổng quát hơn và vận dụng hiệu quả ở các tác vụ ngữ cảnh khác nhau.

1.3 Các phương pháp trước đây

Cho đến nay, hai hướng tiếp cận chính đã được sử dụng để “khắc phục” vấn đề dữ liệu thô không cân bằng:

1. **Curation thủ công hoặc bán tự động**: Ví dụ, các mô hình lớn hiện nay sử dụng cách phối trộn dữ liệu cẩn thận. LLM thường đào tạo trên Wikipedia và sau đó mở rộng trên dữ liệu web đã lọc theo ngôn ngữ, chủ đề tương đương với Wikipedia . Các mô hình ảnh nền tảng lấy ảnh từ kho ngẫu nhiên dựa trên một bộ dữ liệu “hạt giống” có gán nhãn trước đó, nhằm đảm bảo cân bằng tương đối về khái niệm . Ý tưởng chính của phương pháp này là sử dụng

hiểu biết và công sức của con người để điều chỉnh phân bố dữ liệu (ví dụ giới hạn số ảnh của mỗi nhiếp ảnh gia như trong bộ PASS , hay chọn những nguồn dữ liệu chất lượng). Hạn chế cụ thể là những phương pháp này rất tốn kém thời gian và công sức (cần đánh nhãn, loại bỏ, duyệt kiểm thủ công) và khó áp dụng ở quy mô Internet khổng lồ. Thêm vào đó, chúng thường kém khả năng mở rộng: việc nhân rộng quy trình đó để lấy bộ dữ liệu lớn hơn hoặc cho miền mới (chẳng hạn ảnh vệ tinh, văn bản) lại là một thách thức lớn.

2. **Phương pháp tự động dựa trên clustering hoặc sampling**: Ý tưởng chủ đạo là áp dụng thuật toán k-means lên tập dữ liệu chưa gán nhãn để tạo ra các "nhãn ảo" (virtual labels), sau đó lấy số lượng điểm bằng nhau từ mỗi cụm để xây dựng bộ dữ liệu mới. Tuy nhiên, hướng tiếp cận này vướng phải các rào cản lớn:

   - **Hạn chế của k-means đơn giản**: Thuật toán có xu hướng chia các khái niệm chiếm ưu thế thành nhiều cụm nhỏ hơn nhằm giảm tổng sai số nội cụm. Hệ quả là các khái niệm phổ biến bị đại diện bởi quá nhiều cụm, trong khi các khái niệm hiếm lại có quá ít cụm.
   - **Minh chứng thực nghiệm**: Trên tập ảnh web khổng lồ, bài báo chỉ ra rằng có tới **300 trong số 10.000 cụm** chỉ để đại diện cho một khái niệm duy nhất là "website". Điều này làm lệch nghiêm trọng chiến lược lấy mẫu đồng đều, khiến dữ liệu sau lọc vẫn bị mất cân bằng.
   - **Nguyên nhân lý thuyết**: Trong không gian chiều cao, các tâm cụm của k-means phân bố tỉ lệ thuận theo mật độ dữ liệu ban đầu. Do đó, khu vực mật độ cao (phần đầu của phân phối) hiển nhiên sẽ sở hữu nhiều tâm cụm hơn khu vực mật độ thấp (phần đuôi), khiến việc "cân bằng" trở nên bất khả thi.
   - **Sự thất bại của các thuật toán khác**: Các kỹ thuật như *Agglomerative clustering* hay *DBSCAN* cũng cho kết quả không đồng đều tương tự khi áp dụng trên quy mô lớn. Các phương pháp thay thế như tăng trọng số điểm hiếm hoặc sampling ngẫu nhiên thường thiếu cơ sở lý thuyết chặt chẽ và kém hiệu quả thực tế.

   Tóm lại: Mặc dù có ưu điểm về tính tự động, các phương pháp clustering truyền thống vướng phải giới hạn cố hữu về mặt phân bố, khiến việc đạt được trạng thái "cân bằng tự nhiên" là gần như không thể.

1.4 Đóng góp chính của bài báo

Bài báo này có ba loại đóng góp chính: **lý thuyết**, **kỹ thuật** và **thực nghiệm**.

- **Lý thuyết**: Nhóm tác giả phân tích và chứng minh rằng bằng việc áp dụng nhiều lần k-means theo mô hình phân cấp, phân bố của các tâm cụm tiệm cận phân bố đều trên không gian dữ liệu. Cụ thể, trong Định lý 1 họ chứng minh rằng phân biệt Kullback-Leibler giữa phân bố các tâm cụm của k-means và phân bố đều giảm khi số tầng phân cấp tăng . Nói cách khác, cách phân cấp nhiều lần làm các cụm trở nên "phẳng" hơn (đều hơn) theo mỗi cấp.

- **Kỹ thuật**

  Nhóm tác giả đề xuất một quy trình xây dựng tập dữ liệu tự động với các đóng góp kỹ thuật trọng tâm sau:

  - **Thuật toán phân cấp dựa trên k-means**: Nhóm tác giả đề xuất một phương pháp lặp nhiều cấp: cấp 1 chạy k-means trên toàn bộ dữ liệu, sau đó cấp 2 chạy k-means trên các tâm cụm của cấp 1, và tiếp tục lặp lại. Kết quả tạo ra một cây cụm (*hierarchy*) trong đó các nút lá là dữ liệu gốc và các nút ở tầng cao hơn đại diện cho tâm cụm ở mỗi cấp độ trừu tượng.
  - **Bước Resampling (Lấy mẫu lại)**: Để ổn định chi phí tính toán và giữ kích thước dữ liệu đủ lớn, tại mỗi cấp (trừ cấp cuối cùng), thuật toán thực hiện thêm bước *resampling*: từ mỗi cụm của cấp trước, chọn một tập con nhỏ các điểm gần tâm để làm đầu vào cho lượt chạy k-means cấp sau. Quy trình chi tiết của thuật toán được mô tả dưới đây:

Algorithm 1: Hierarchical k-means with resampling algorithm.

Input: Data $X \in \mathbb{R}^{n \times d}$, number of levels T, number of clusters per level $(k_t)_{1 \le t \le T}$, number of resamplings m, number of points resampled per cluster $(r_t)_{1 \le t \le T}$.

Result: A hierarchy of clusters on data: centroids $(C_t)_{1 \le t \le T}$ and clusters $((L_t^{(i)})_{1 \le i \le k_t})_{1 \le t \le T}$.

```
for t = 1 to T do
    if t = 1 then I ← X else I ← C_{t-1}                ▷ Get input I of level t
    C_t ← kmeans(I, k_t)                                ▷ Find centroids C_t with k-means
    L_t ← assign(I, C_t)                                ▷ Assign clusters (L_t^(i))_{1≤i≤n_t} with k-means
    # resampling-clustering
    for s = 1 to m do
        R ← ⋃_{i=1}^{k_t} resample(L_t^(i), r_t)        ▷ Sample r_t points from each cluster
        C_t ← kmeans(R, k_t)                            ▷ Find centroids based on resampled set
        L_t ← assign(I, C_t)                            ▷ Assign clusters to entire input set of level t
    end
end
```

Hình 1: Thuật toán 1: Hierarchical k-means kết hợp resampling.

- **Chiến lược lấy mẫu từ cây cụm**: Sau khi hoàn thành cây cụm, tác giả đề xuất hai chiến lược để tạo tập dữ liệu cuối cùng:
  * *Flat sampling*: Chọn đều các điểm từ các nhánh ở cấp cao nhất.
  * *Hierarchical sampling*: Lấy mẫu đệ quy từ trên xuống dưới để đảm bảo sự cân bằng ở nhiều mức độ khái niệm khác nhau.
- **Thử nghiệm cách lấy điểm trong cụm**: Nhóm nghiên cứu đã thử nghiệm ba phương pháp lấy điểm trong mỗi cụm bao gồm: ngẫu nhiên (r), gần tâm (c), và xa tâm (f). Kết quả thực nghiệm cho thấy việc **lấy mẫu ngẫu nhiên** thường mang lại hiệu năng cao nhất cho việc học biểu diễn tự giám sát.

- **Thực nghiệm**: Bài báo chứng minh rằng tập dữ liệu do phương pháp này tạo ra cải thiện đáng kể hiệu năng so với dữ liệu thô. Trên ba miền dữ liệu khác nhau (ảnh web, văn bản, ảnh vệ tinh), mô hình SSL được huấn luyện trên dữ liệu do tác giả xây dựng có độ chính xác cao hơn nhiều so với khi huấn luyện trên dữ liệu chưa được cân bằng , và thậm chí tương đương hoặc tốt hơn mô hình huấn luyện trên dữ liệu thủ công có cân bằng. Một kết quả nổi bật là các đặc trưng SSL từ dữ liệu được cân bằng tự động này cho độ phân giải (robustness) cao hơn cả mô hình huấn luyện trên ImageNet-22k (dữ liệu phức tạp được cân bằng cẩn thận bởi con người) trên một số nhiệm vụ . Những kết quả này chứng tỏ cả tính khả thi lẫn hiệu quả của phương pháp đề xuất, mang lại cải thiện rõ rệt trên các bài toán phân loại, truy hồi ảnh, ước lượng ảnh vệ tinh, và đánh giá mô hình ngôn ngữ.

2 Phương pháp đề xuất

2.1 Ký hiệu và bài toán

Bài báo đặt vấn đề kỹ thuật thông qua các thành phần ký hiệu và mục tiêu toán học cụ thể như sau:

- **Phân phối và Dữ liệu gốc**: Cho một phân phối dữ liệu gốc P (ví dụ: toàn bộ dữ liệu Internet) và một mẫu $X = \{x_i\}$ được lấy từ P. Các điểm dữ liệu này được đại diện dưới dạng các vectơ trong *không gian nhúng* ($\mathbb{R}^D$ - không gian vectơ nơi các đặc điểm ngữ nghĩa được số hóa để máy tính có thể tính toán).

- **Mục tiêu chọn mẫu**: Nhiệm vụ là chọn ra một tập con $S \subset X$ sao cho các điểm trong S có tính chất như được lấy mẫu từ một phân phối đều U trên *hỗ trợ* (*support* - tập hợp các giá trị mà tại đó hàm mật độ xác suất khác không) của P.

- **Công thức hóa mật độ**: Nếu gọi $\rho(x)$ là hàm mật độ của P, mục tiêu là chọn S sao cho phân phối trên S tiến đến $\rho_U(x) = 1/\mathrm{Vol}(\mathrm{supp}(P))$. Điều này có nghĩa là mỗi vùng của không gian dữ liệu (tương ứng với một khái niệm cụ thể) đều có xác suất được lựa chọn xấp xỉ bằng nhau, loại bỏ sự áp đảo của các lớp phổ biến.

- **Yêu cầu về không gian nhúng**: Nhóm tác giả nhận định cần một không gian đặc trưng mà trong đó khoảng cách toán học giữa các vectơ phản ánh chính xác khoảng cách ngữ nghĩa giữa các khái niệm. Ví dụ: Sử dụng mạng ViT-L huấn luyện bằng thuật toán DINOv2 trên ImageNet để trích xuất các đặc trưng hình ảnh chất lượng cao.

- **Chiến lược thực thi**: Sau khi thiết lập không gian nhúng, mục tiêu cuối cùng là lựa chọn các cụm hoặc điểm dữ liệu sao cho chúng phân bổ "đều" nhất có thể trên không gian này, thay vì tập trung vào các vùng có mật độ dữ liệu cao.

2.2 Kiến trúc và pipeline

Toàn bộ quy trình (*pipeline*) của phương pháp được mô tả chi tiết thông qua các bước sau:

- **Tiền xử lý dữ liệu thô**: Trên mỗi miền dữ liệu (ảnh web, văn bản, vệ tinh), tác giả tập hợp một kho dữ liệu thô rất lớn (ví dụ: 743 triệu ảnh web sau lọc). Họ áp dụng các bước lọc ban đầu như loại bỏ trùng lặp, ảnh quá nhỏ, ảnh chứa nội dung nhạy cảm hoặc khuôn mặt, để đảm bảo dữ liệu "sạch" và đa dạng.

- **Tách đặc trưng (embedding)**: Với dữ liệu ảnh, họ dùng mô hình ViT-L huấn luyện DINOv2 để trích xuất vectơ đặc trưng $f(x) \in \mathbb{R}^D$ cho mỗi ảnh. Tương tự với văn bản, có thể dùng SBERT (Reimers & Gurevych) để lấy embedding. Các vectơ này phản ánh chính xác ngữ nghĩa của từng điểm dữ liệu trong không gian đặc trưng.

- **Hierarchical k-means + Resampling**: Trên toàn bộ tập dữ liệu X, áp dụng thuật toán k-means nhiều cấp. Cấp 1 chạy k-means với K_1 cụm trên X; cấp 2 chạy k-means với K_2 cụm trên các tâm cụm (*centroids*) của cấp 1; lặp lại quá trình này đến cấp L với K_L cụm.

- Kết quả là một cây cụm (hierarchy): mỗi nút ở cấp l bao gồm một tập các ảnh ở cấp lá và có một tâm cụm tương ứng.
- Đặc biệt, để giảm chi phí và giữ kích thước dữ liệu lớn, tại mỗi cấp (trừ cấp cuối) còn thực hiện thêm bước *resampling*: từ mỗi cụm ở cấp trước, chọn một số điểm gần tâm nhất tạo thành một tập con nhỏ, rồi chạy k-means trên tập con này để tìm centroid mới.
- Bước này giúp giảm lượng dữ liệu đầu vào và làm phân bố centroid "phẳng" hơn ở các cấp kế tiếp. Thông qua quá trình này, các centroid ở cấp cao ngày càng phân bố gần với phân phối đều hơn (Lemma 1).

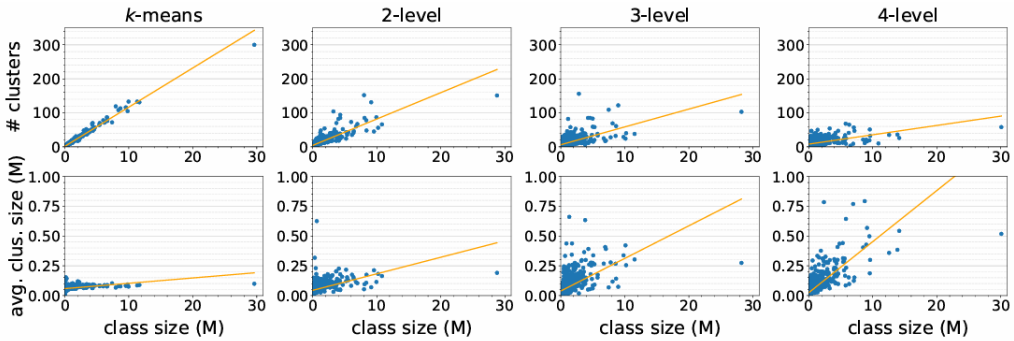

Hình 2: : Minh họa phân bố các cụm theo kích thước lớp trong ImageNet khi sử dụng k-means thông thường (cột đầu tiên) và hierarchical k-means nhiều cấp (các cột tiếp theo). Các điểm xanh đại diện cụm được gán vào lớp tương ứng, đường vàng là xu hướng tuyến tính. Quan sát cho thấy hierarchical k-means nhiều cấp tạo các cụm lớn hơn cho các lớp lớn và phân bố cụm đồng đều hơn giữa các lớp so với k-means thông thường.

- **Lấy mẫu cân bằng**: Sau khi có cây cụm, tác giả thực hiện chọn tập con dữ liệu cuối cùng (*final subset*). Hai chiến lược được đề xuất bao gồm:
  - *Flat sampling*: Chọn đều một số lượng điểm nhất định từ mỗi cây con ở cấp cao nhất.
  - *Hierarchical sampling*: Lấy mẫu đệ quy từ trên xuống. Với kích thước mục tiêu N cho trước, thuật toán tính toán số điểm cần lấy từ mỗi cụm ở tất cả các cấp sao cho tổng cộng đạt xấp xỉ N.

  Kết quả thu được là một tập con có độ lớn gần N ảnh, trải đều các khái niệm ở mọi cấp độ (từ các khái niệm lớn ở cấp cao đến các khái niệm nhỏ ở cấp thấp).

Tóm lại, pipeline bắt đầu từ kho dữ liệu thô, đi qua các bước trích xuất embedding(ta giả sử embedding này làm tốt nhiệm vụ), phân cấp k-means kết hợp resampling, và cuối cùng là sampling

để tạo tập dữ liệu đã cân bằng. Tập dữ liệu này sau đó được dùng để huấn luyện mô hình SSL (ví dụ DINOv2) và đánh giá trên các tác vụ hạ nguồn.

2.3 Các thành phần kỹ thuật

Trong pipeline trên, các thành phần chính gồm:

- ***k-means và hierarchical k-means***: Thuật toán cơ bản để phân chia dữ liệu. Trong mỗi cấp, k-means tìm các centroid để tối thiểu tổng sai số bình phương trong từng cụm . Việc sử dụng k-means phân cấp nhằm xấp xỉ phân phối đều: mỗi lần phân cấp làm phẳng thêm phân bố centroid. Mục đích của k-means là nhóm các điểm có ngữ nghĩa gần nhau.

- ***Resampling***: Tại mỗi cấp (ngoại trừ cuối cùng), sau khi tìm các centroid, thuật toán lấy một tập con nhỏ gồm các điểm gần tâm từ mỗi cụm và chạy lại k-means trên tập con đó để tinh chỉnh centroid . Điều này giúp tránh giảm nhanh kích thước dữ liệu và đẩy phân bố centroid tiến về gần đều hơn.

- ***Sampling trong cụm (r, c, f)***: Khi đã có cây cụm và xác định số điểm cần lấy từ mỗi cụm, nhóm tác giả thử ba cách chọn điểm: (r) ngẫu nhiên, (c) chọn điểm gần tâm nhất, (f) chọn điểm xa tâm nhất. Họ quan sát rằng chọn ngẫu nhiên thường cho hiệu năng cao nhất trên hầu hết các bài toán . Chiến lược này cân bằng giữa đặc trưng đại diện và tính đa dạng của dữ liệu.

- ***Định lý và kiến thức lý thuyết***: Bên cạnh thuật toán, bài báo có phát biểu lý thuyết (Lemma 1) nói về hiệu quả của việc tăng độ lệch trong k-means: nếu thay vì đo khoảng cách bình thường (power 2) ta dùng power α, khi α tăng thì phân bố centroids càng phẳng hơn. Tác giả kết luận rằng các centroid của k-means nhiều cấp tiệm cận phân phối đều (Lemma 1) . Đây là cơ sở lý thuyết cho việc lặp lại phân cấp.

2.4 Tính chất lý thuyết

Các thuộc tính toán học của phương pháp được nhóm tác giả phân tích và chứng minh thông qua các khía cạnh trọng tâm sau:

- **Cơ chế phẳng hóa phân phối**: Ý nghĩa của định lý và các phân tích trong bài báo chỉ ra rằng: việc áp dụng phân cấp k-means với nhiều cấp độ tương đương với việc tăng độ lệch (bias) của hàm mục tiêu. Quá trình này cuối cùng sẽ đưa phân bố của các tâm cụm (*centroids*) tiệm cận về phân phối đều (*uniform distribution*) trên không gian dữ liệu.

- **Minh chứng trực quan qua mô phỏng 2D**: Trong thực nghiệm minh họa trên không gian 2D (Hình 3), các kết quả đánh giá thông qua độ đo phân biệt *Kullback-Leibler* (KL divergence) cho thấy sự khác biệt rõ rệt giữa các phương pháp:

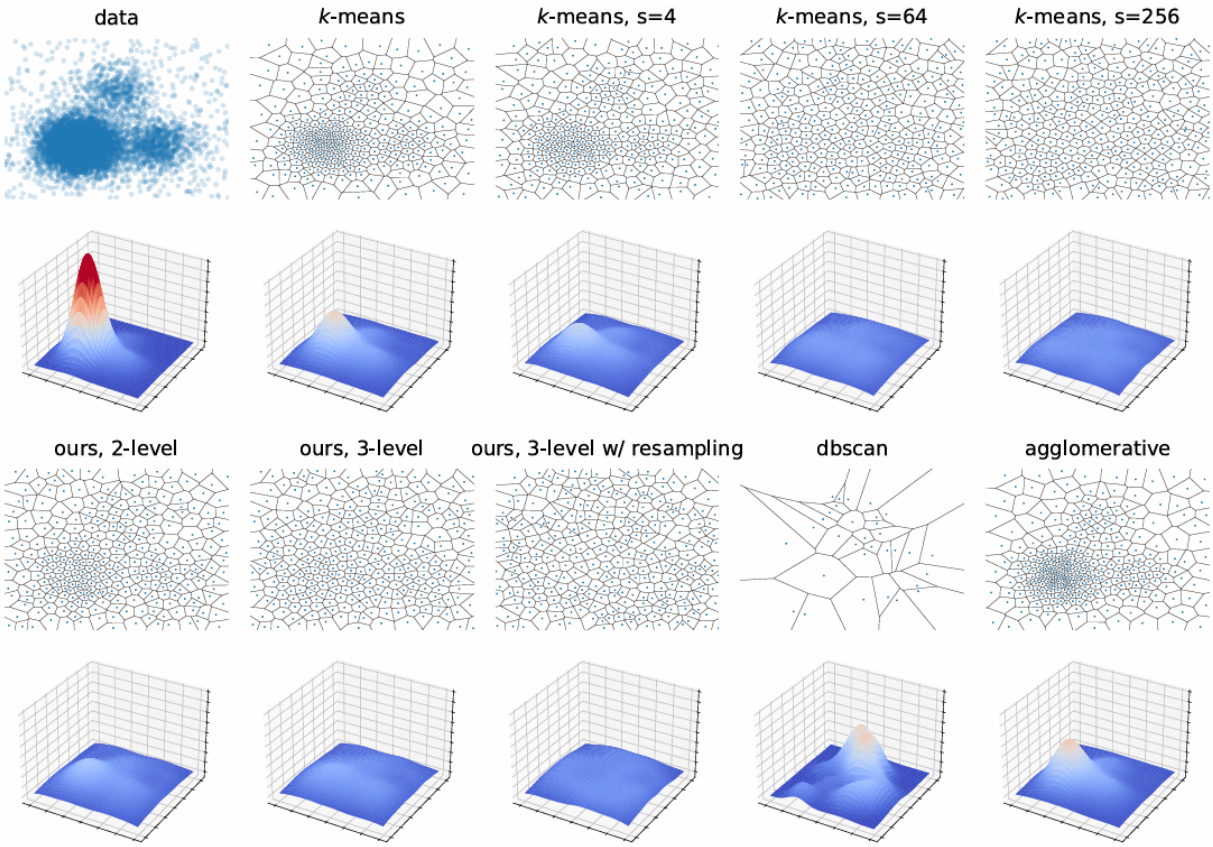

Hình 3: So sánh phân bố tâm cụm và bản đồ mật độ giữa k-means thông thường, các phương pháp truyền thống (DBSCAN, Agglomerative) và phương pháp đề xuất.

Giải thích hình ảnh: Quan sát hàng cuối cùng, phương pháp **ours, 3-level w/ resampling** cho thấy các ô Voronoi có kích thước tương đồng và bản đồ mật độ (density map) phẳng hoàn toàn (màu xanh đều). Trong khi đó, k-means thông thường, DBSCAN và Agglomerative clustering vẫn bị ảnh hưởng nặng nề bởi mật độ dữ liệu gốc, tạo ra các đỉnh nhọn (màu đỏ) tại vùng dữ liệu dày đặc.

- **Xác nhận trên dữ liệu ảnh thực tế**: Dữ liệu thực nghiệm trên ImageNet cũng xác nhận tính đúng đắn của lý thuyết: khi xét từng lớp của ImageNet, thuật toán k-means thông thường tạo ra nhiều cụm nhỏ tập trung ở các lớp lớn. Ngược lại, *hierarchical k-means* nhiều cấp tạo ra các cụm có kích thước lớn hơn cho các lớp lớn, dẫn đến số lượng cụm được phân bố đồng đều hơn giữa các lớp khác nhau.

- **Đảm bảo tính tiệm cận**: Tóm lại, về mặt lý thuyết, phương pháp đề xuất đảm bảo khả năng tiệm cận mục tiêu ban đầu là đạt được phân phối đều khi số lượng cấp phân cấp đủ lớn và không gian nhúng (*embedding*) có cấu trúc phân tách tốt.

2.5 Độ phức tạp

Về *thời gian*: Thuật toán k-means trên N điểm và K cụm thông thường mất $O(NKD)$ mỗi vòng. Ở cấp 1, tác giả chạy k-means với $K_1 = 10^7$ trên $N = 743 \times 10^6$ ảnh – đây là quy mô rất lớn, nên họ phải dùng tính toán phân tán GPU, tối ưu khởi tạo (k-means++), và resampling để giảm chi phí . Mỗi cấp l tiếp theo chỉ làm trên K_{l-1} tâm cụm của cấp trước, nên chi phí mỗi cấp giảm theo cấp. Tóm lại, thuật toán phức tạp hơn một lần k-means thông thường, nhưng đổi lại mang lại dữ liệu phân bố tốt hơn.

Về *bộ nhớ*: Cần lưu toàn bộ điểm N và centroid của mỗi cấp. Trong mô hình thí nghiệm, số lượng centroid lớn nhất là $K_1 = 10^7$. Nếu sử dụng phân tán, GPU tải từng phần dữ liệu, CPU lưu trữ toàn bộ. Đây là thách thức thực tế, nhưng đã được nhóm tác giả giải quyết với hạ tầng lớn. Tổng thể, phương pháp này đòi hỏi tài nguyên cao nhưng mang lại cải thiện về chất lượng dữ liệu.

3 Phân tích phê bình

3.1 Điểm mạnh

Phương pháp đề xuất sở hữu ba ưu điểm cốt lõi giúp giải quyết hiệu quả các hạn chế của các hướng tiếp cận truyền thống:

- **Tự động và tổng quát**: Phương pháp hoàn toàn không yêu cầu nhãn hay sự can thiệp thủ công (hoặc chỉ cần một mô hình embedding đã học trước), cho phép áp dụng linh hoạt trên bất kỳ tập dữ liệu lớn không gán nhãn nào. Tính ứng dụng rộng rãi của thuật toán đã được

minh chứng thực nghiệm trên đa dạng miền dữ liệu từ hình ảnh, văn bản cho đến ảnh vệ tinh chuyên biệt với cùng một quy trình xử lý duy nhất.

- **Cân bằng khái niệm**: Kết quả thực nghiệm khẳng định cấu trúc *hierarchical k-means* (phân cấp 4 tầng) tạo ra bộ dữ liệu có sự phân bổ giữa các khái niệm phổ biến và khái niệm hiếm đồng đều hơn hẳn so với k-means thông thường.

(a) Influence of numbers of levels of hierarchical k-means.

dataset	imagenet		ood		long-tailed		retrieval
	knn	val	in-A	sketch	inat18	inat21	oxf-H
raw	73.6	82.8	46.9	54.0	65.9	73.8	14.3
1r	76.6	83.9	58.0	57.0	70.1	77.7	16.3
2r	78.7	84.5	65.4	60.0	73.8	80.8	24.7
3r	78.7	84.5	64.7	60.1	**76.2**	**82.3**	29.7
4r	**79.6**	**84.7**	**66.4**	**60.5**	75.7	**82.3**	**32.1**

Hình 4: Bảng (a): Tác động của số lượng cấp phân cấp (từ raw đến 4r) đối với hiệu năng mô hình trên các tập dữ liệu khác nhau.

Minh chứng cụ thể từ bảng số liệu trên, mô hình huấn luyện trên bộ dữ liệu phân cấp đạt độ chính xác cao hơn đáng kể (tăng khoảng +6% top-1) trên ImageNet (k-NN) so với khi dùng dữ liệu thô: tăng từ **73.6%** (dòng *raw*) lên **79.6%** (dòng *4r*). Ngoài ra, các chỉ số trên tập dữ liệu lệch (*long-tailed*) như inat18 và inat21 cũng tăng trưởng mạnh mẽ (ví dụ: inat21 tăng từ 73.8% lên 82.3%), xác nhận đầu ra của thuật toán đạt được tính "đồng đều về khái niệm" như mục tiêu đề ra.

Hiệu năng thực nghiệm cao: Việc cân bằng dữ liệu tự động giúp mô hình SSL học được những đặc trưng (features) vô cùng mạnh mẽ. Trên nhiều bài toán từ phân loại chuẩn đến các nhiệm vụ thách thức (ImageNet-A, Sketch, ObjectNet) hay phân loại trên dữ liệu phân phối lệch (iNaturalist), phương pháp này luôn cho kết quả vượt trội so với dữ liệu thô. Đặc biệt, trong nhiều trường hợp, mô hình tự động của tác giả còn vượt qua cả các mô hình học từ **ImageNet-22k** (dữ liệu được con người tuyển lọc thủ công), khẳng định lợi ích thực tế trong việc cải thiện độ bền vững (*robustness*) và khả năng tổng quát hóa của các tính năng học được.

3.2 Hạn chế

Mặc dù có nhiều ưu điểm, phương pháp đề xuất vẫn tồn tại một số hạn chế cần được xem xét:

- **Cần embedding chất lượng ban đầu**: Phương pháp dựa hoàn toàn vào không gian embedding đã học trước (ví dụ DINOv2 được huấn luyện trên ImageNet). Nếu embedding kém, các cụm sẽ không phản ánh đúng khái niệm thực tế, dẫn đến việc chọn mẫu không hiệu quả. Bài báo cũng thừa nhận điều này khi sử dụng DINOv2 từ ImageNet-1k làm embedding cơ sở. Như vậy, phương pháp chưa hoàn toàn "tự động" mà vẫn phụ thuộc đáng kể vào công sức huấn luyện các mô hình tiền đề.

- **Chi phí tính toán cao**: Việc thực thi *multi-level k-means* trên hàng trăm triệu điểm dữ liệu đòi hỏi tài nguyên hệ thống rất lớn về cả GPU và bộ nhớ. Mặc dù các kỹ thuật như Resampling và tính toán phân tán đã giúp giảm bớt gánh nặng này, nhưng quy trình nhìn chung vẫn rất nặng nề. Việc triển khai thành công đòi hỏi một hạ tầng phần cứng mạnh mẽ mà không phải đơn vị nghiên cứu nào cũng có thể tiếp cận.

- **Không xử lý chất lượng ảnh xấu**: Phương pháp hiện tại chỉ tập trung vào việc cân bằng số lượng giữa các cụm khái niệm mà chưa có cơ chế đánh giá chất lượng hoặc tính đại diện của từng điểm ảnh cụ thể. Ví dụ, nếu tập dữ liệu đầu vào chứa nhiều nhiễu (ảnh mờ, ảnh lỗi), thuật toán vẫn sẽ tiếp nhận chúng vào bộ dữ liệu huấn luyện mà không có sự phân biệt. Vấn đề này có thể cần được giải quyết thêm thông qua các bước tiền xử lý hoặc lọc dữ liệu chuyên sâu hơn.

- **Thiếu kiểm soát đặc thù**: Thuật toán mang tính tổng quát cao nhưng lại kém linh hoạt đối với những mục tiêu ứng dụng cụ thể. Ví dụ, trong các trường hợp cần ưu tiên một số khái niệm theo ngữ cảnh đặc thù (như tính công bằng - *fairness*, các tiêu chuẩn đạo đức, v.v.), quy trình (*pipeline*) này chưa cung cấp cách thức tích hợp sẵn. Mặc dù tác giả có đề cập đến khả năng tinh chỉnh thông qua các chỉ số cân bằng, nhưng khả năng can thiệp sâu hơn vào dữ liệu vẫn còn khá hạn chế.

3.3 Giả định ngầm

Embedding phản ánh ngữ nghĩa: Phương pháp giả định không gian embedding đã học trước có cấu trúc tốt, nghĩa là các điểm dữ liệu cùng khái niệm nằm gần nhau. Nếu embedding yếu, clustering sẽ không đúng. **Dữ liệu phân phối liên tục và đầy đủ**: Bài báo giả định phân phối P có hỗ trợ rộng và đều đặn. Nếu trong dữ liệu ban đầu có nhiều vùng trống hoặc thiếu một số khái niệm quan trọng, việc cân bằng trên dữ liệu tồn tại không giải quyết được hoàn toàn. **Không gian Euclid ổn định**: k-means dùng metric Euclid$\hat{2}$, giả định metric này phản ánh đúng độ tương đồng. Điều này có thể không tối ưu nếu dữ liệu có cấu trúc phi tuyến, nhưng bài báo cho rằng kết quả thực nghiệm chứng tỏ metric này là tương đối hợp lý trong không gian embedding.

3.4 Hướng phát triển

Dựa trên những hạn chế và kết quả đã đạt được, bài báo gợi mở các hướng nghiên cứu tiềm năng sau:

- **Loại bỏ phụ thuộc embedding có giám sát**: Hiện tại, phương pháp phụ thuộc vào mô hình embedding đã huấn luyện trước (như ImageNet). Một hướng tiếp theo là kết hợp curation với việc học embedding: ví dụ, khởi tạo embedding ngẫu nhiên, phân cụm lấy mẫu bộ dữ liệu cân bằng, dùng bộ dữ liệu đó huấn luyện SSL để cải thiện embedding, rồi lặp lại quy trình này một cách tuần hoàn.

- **Tối ưu hóa hiệu quả tính toán**: Nghiên cứu các thuật toán clustering xấp xỉ hoặc kỹ thuật *sketching* để giảm chi phí tính toán. Ví dụ, áp dụng LSH (Locality-Sensitive Hashing) hoặc clustering phân tán tối ưu hơn để xử lý nhanh hàng chục triệu điểm dữ liệu, đồng thời tự động chọn số cụm và số cấp hợp lý dựa trên đặc thù dữ liệu.

- **Curation có điều chỉnh mục tiêu**: Phát triển phương pháp để kết hợp các tiêu chí bổ sung (ví dụ: tính công bằng - *fairness*, đa dạng văn hóa) vào thuật toán curation. Nếu cần ưu tiên hoặc hạn chế một số khái niệm theo yêu cầu cụ thể, pipeline hiện có thể được điều chỉnh thông qua các tham số clustering hoặc thiết kế lại hàm mục tiêu đa nhiệm.

- **Ứng dụng trong active learning và data pruning**: Như tác giả gợi ý, *hierarchical k-means* có thể thay thế k-means thông thường trong các bài toán chọn mẫu tích cực (*active*

learning) hoặc cắt giảm dữ liệu dư thừa (*data pruning*). Đây là hướng tiềm năng khi cần xây dựng tập dữ liệu đại diện chất lượng cao từ các kho dữ liệu lớn chưa gán nhãn.

- **Áp dụng cho dữ liệu đa phương thức**: Mở rộng pipeline sang các phương thức (*modal*) khác như kết hợp song song ảnh và văn bản, hoặc xử lý video và âm thanh. Ví dụ, xây dựng tập dữ liệu cân bằng kết hợp thông tin đa modal để phục vụ huấn luyện các mô hình đa phương thức quy mô lớn.

- **Đánh giá mở rộng**: Thực hiện thực nghiệm trên nhiều nhiệm vụ khác (ví dụ: tạo mẫu, đối thoại, nhãn công nghiệp) để đánh giá toàn diện hơn. Nghiên cứu sâu thêm về chất lượng bộ dữ liệu, tính công bằng và độ an toàn trong các ứng dụng thực tế.

Tóm lại, bài báo đề xuất một hướng tiếp cận có tính nguyên tắc và toàn diện để chọn lọc dữ liệu cho SSL một cách tự động. Các phân tích và thử nghiệm đều khẳng định lợi ích cốt lõi của việc cân bằng khái niệm, đồng thời cung cấp lộ trình phát triển rõ ràng để khắc phục các hạn chế hiện tại.

4 Tái hiện thực nghiệm

4.1 Thực nghiệm trên dữ liệu mô phỏng (Synthetic Data 2D)

Thực nghiệm này tái hiện lại Mục 4.1 (1) trong bài báo gốc để kiểm chứng kiểm tra tính đúng đắn của thuật toán Hierarchical K-means Resampling do nhóm cài đặt so với thuật toán do tác giả viết. Đồng thời kiểm chứng khả năng "làm phẳng" (flattening) phân phối dữ liệu của thuật toán trong môi trường kiểm soát 2D.

4.1.1 Thiết lập dữ liệu và tham số thực nghiệm

Nhóm khởi tạo bộ dữ liệu mô phỏng gồm $n = 9.000$ điểm trong không gian $\Omega = [-3, 3] \times [-3, 3]$ với phân phối cực kỳ mất cân bằng (Long-tailed distribution) theo đúng cài đặt của tác giả nhờ tham khảo mã nguồn trên Github (nhưng không thể tái hiện thành công vì source code tác giả không sử dụng random_state cố định):

- **Cụm đậm đặc (Head):** 7.000 điểm tập trung tại Gaussian tâm $[-1, -1]$.

- **Cụm trung bình:** Lần lượt 1.000 điểm và 500 điểm tại các tâm $[1, -1]$ và $[0, 1]$.
- **Dữ liệu nền (Tail/Noise):** 500 điểm phân phối đều (Uniform) trên toàn bộ không gian Ω.

Trong tất cả các thử nghiệm, số lượng cụm mục tiêu được cố định là $k = 300$. Các tham số cho HK-means được thiết lập với $T = 3$ levels, số lần resampling $m = 10$ và chiến lược lấy mẫu *closest* theo đúng cài đặt của tác giả.

4.1.2 Phân tích kết quả tái thực nghiệm trên dữ liệu mô phỏng 2D

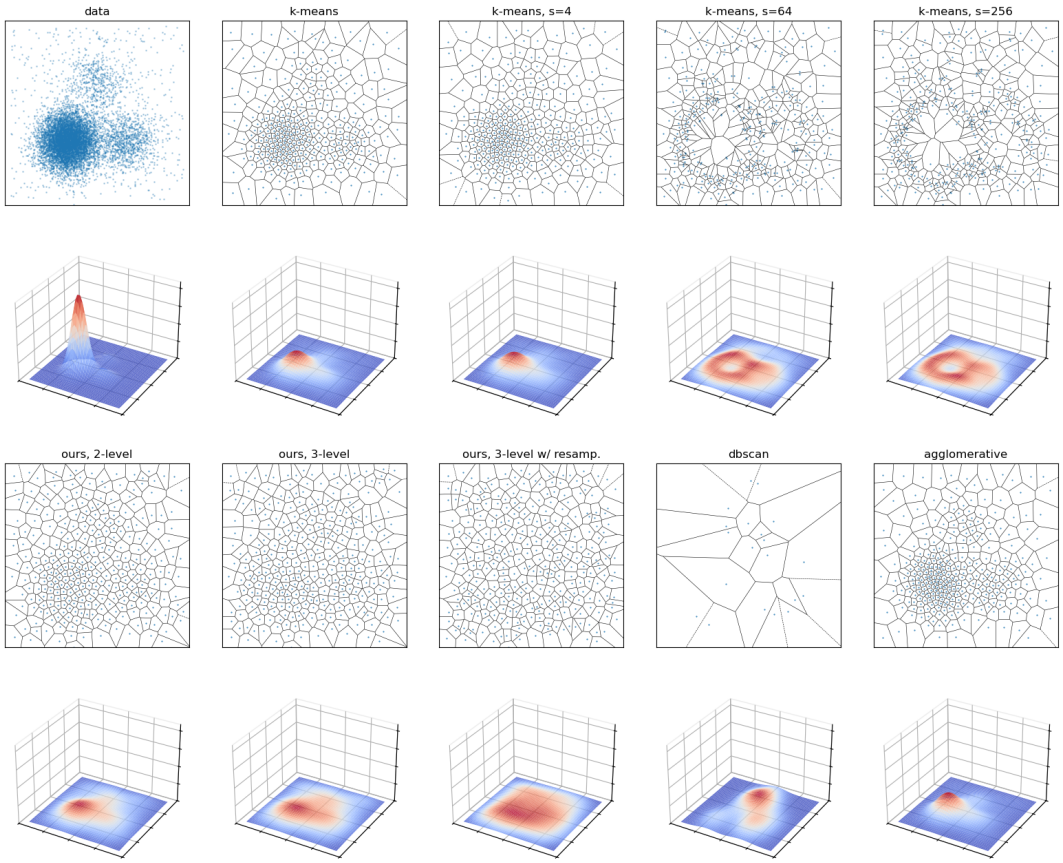

Hình 5: Kết quả trực quan hóa cấu hình tâm cụm: Bản đồ Voronoi (Hàng 1, 3) thể hiện sự phân bổ không gian và Bề mặt KDE 3D (Hàng 2, 4) thể hiện mật độ của các centroids. Thuật toán HK-means với resampling tạo ra bề mặt phẳng nhất, minh chứng cho sự phân bổ đồng nhất.

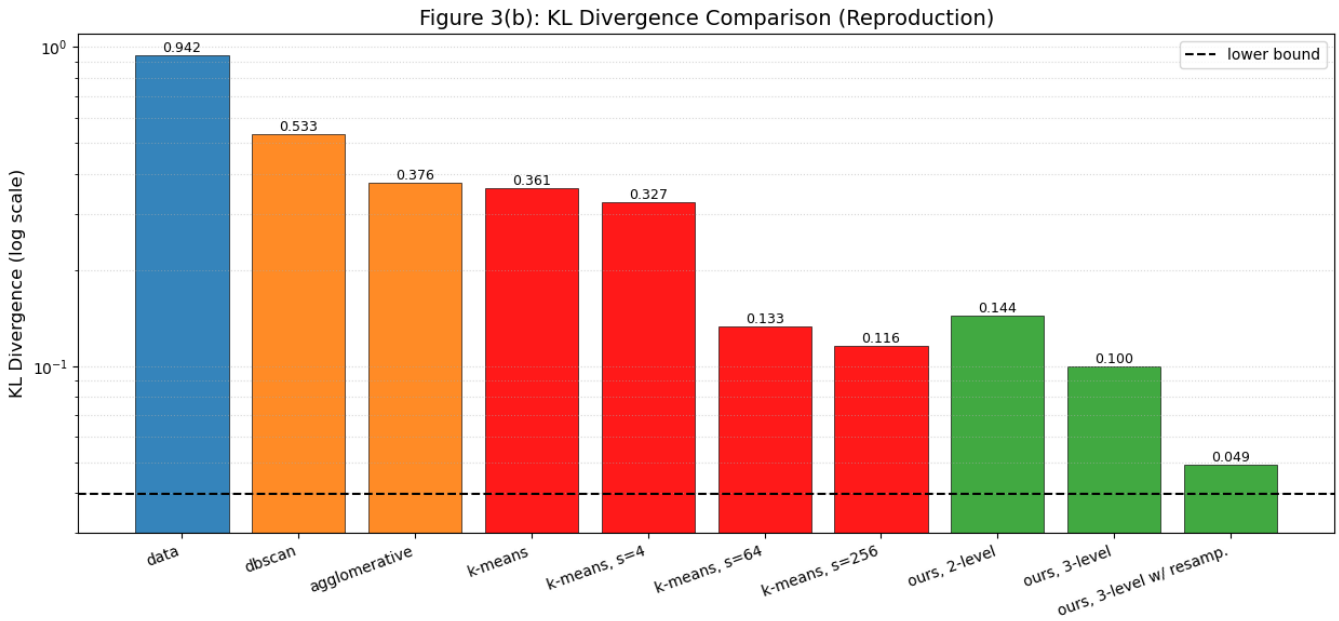

Hình 6: So sánh chỉ số KL Divergence giữa các phương pháp trên dữ liệu mô phỏng 2D. Các thanh màu xanh lá (HK-means) thể hiện độ phẳng vượt trội so với các phương pháp truyền thống và bám sát đường Lower Bound lý thuyết.

Nhóm sử dụng độ đo Kullback-Leibler (KL) Divergence (hàm `calculate_kl_divergence` được cài đặt tại `src/metrics.py`) giữa ước lượng mật độ hạt nhân (KDE) của các tâm cụm và phân phối đều U để đánh giá hiệu quả. Bên cạnh đó, nhóm phân tích sự thay đổi của các tâm cụm (centroids) qua hai khía cạnh chính: cấu trúc hình học Voronoi và bề mặt mật độ xác suất KDE 3D. Kết quả thu được Hình 5 và Hình 6 thể hiện rõ xu hướng cải thiện:

- **Baseline (DBSCAN & Agglomerative Clustering):** Kết quả thực nghiệm cho thấy hai phương pháp này có chỉ số KL cao nhất (0.533 và 0.376), hoàn toàn khớp với nhận định của tác giả tại Mục 3.2 và 4.1 (1).
  - *Nguyên nhân:* Các ô Voronoi của DBSCAN có hình dạng méo mó, kích thước không đều và không phủ đều toàn bộ không gian. Nguyên nhân là do DBSCAN hoạt động dựa trên mật độ điểm: những vùng có nhiều điểm (vùng dày) sẽ tạo thành cụm rõ ràng, trong khi những vùng ít điểm (vùng thưa) thường bị xem là nhiễu và bị bỏ qua. Vì vậy, các điểm đại diện cho cụm chỉ xuất hiện quanh những vùng dày, còn các vùng thưa gần như không được đại diện. Điều này khiến phân bố các cụm bị lệch, không trải đều trên không gian, và do đó không phân bố đồng đều như các phương pháp khác.

- Với Agglomerative Clustering, các ô Voronoi thể hiện rõ hiện tượng *density bias*. Ở các vùng dữ liệu dày đặc (các cụm Gaussian), các ô có diện tích rất nhỏ, trong khi ở vùng dữ liệu thưa (phân phối Uniform), các ô lại giãn nở rất lớn. Đó là do thuật toán có xu hướng chia dữ liệu sao cho các cụm có độ biến thiên tương đương. Điều này khiến các vùng dày bị chia nhỏ thành nhiều cụm, thay vì phân bố đều trong không gian. Kết quả là phương pháp này cũng không cân bằng được dữ liệu.

- **K-means với hàm biến dạng (distortion)** s **(**$s \in \{4, 16, 64, 256\}$**):** Nhóm đã tự cài đặt tái hiện kỹ thuật tăng dần số mũ s qua các bước `s_steps` để ép các tâm cụm dãn cách đều hơn. Tuy nhiên, nhóm quan sát thấy một hiện tượng đặc biệt ở Hình 5: khi s nhỏ ($s = 4$), các tâm cụm nằm gọn ở giữa các vùng dữ liệu. Nhưng khi s tiến tới 256, các tâm cụm bắt đầu có dấu hiệu **dao động hỗn loạn** và không còn nằm ngay ngắn ở giữa các cụm nữa.

  - *Giải thích kỹ thuật:* Việc tối thiểu hóa hàm lỗi $\sum \|x_i - c\|^s$ (x_i: điểm dữ liệu, c: tâm cụm, s: số mũ distortion) dẫn đến công thức cập nhật centroid là một trung bình có trọng số với $w_i = \|x_i - c\|^{s-2}$ (w_i: trọng số điểm i). Khi s tiến tới 256, số mũ $s - 2 = 254$ khiến các điểm ở biên cụm có trọng số lớn áp đảo so với các điểm gần tâm. Điều này khiến chỉ cần một thay đổi nhỏ của các điểm xa nhất cũng tạo ra Gradient cực lớn kéo centroid văng khỏi vị trí ổn định.

  - *Insight từ bài báo:* Tác giả **đã dự báo chính xác** vấn đề này tại trang 8 (Mục 3.2): *"a too large value of s leads to numerical instability"* (1). Việc nhóm cho rằng sự hỗn loạn này không phải do cài đặt sai, mà là **xác nhận thực nghiệm** cho lý do tại sao tác giả không sử dụng s lớn trong thực tế mà phải đề xuất Hierarchical K-means như một giải pháp thay thế ổn định hơn.

- **Sự vượt trội và tính ổn định của HK-means:** Khi tăng số tầng phân cấp (từ 2-level đến 3-level và 3-level kết hợp resampling), các ô Voronoi dần trở nên đồng đều về diện tích trên toàn bộ không gian. Ở cấu hình tốt nhất (3-level w/ resampling), các ô có diện tích khá tương đương nhau ở vùng giữa không gian. Trong khi các phương pháp K-means với số mũ s lớn đạt được độ phẳng nhưng lại rơi vào trạng thái hỗn loạn về mặt vị trí tâm cụm, thuật toán HK-means (Ours) cho thấy sự kết hợp tốt giữa **độ phẳng tối ưu** và **tính ổn định**. Với cấu

hình 3 tầng ($T = 3$) kết hợp resampling, nhóm đã đạt được chỉ số KL Divergence thấp nhất là 0.0492, bám sát kết quả gốc của tác giả (0.0405).

  - *Tính ổn định so với phương pháp lũy thừa:* Khác với cách tăng $s = 256$ khiến các tâm cụm dễ bị kéo lệch ra biên do ảnh hưởng mạnh của các điểm rìa, HK-means phân cụm theo nhiều tầng nên ổn định hơn. Mỗi tầng giúp làm "mượt" dần phân bố dữ liệu, giúp các centroid được dàn đều mà không cần dùng phép lũy thừa lớn.

- **Bề mặt mật độ KDE 3D:**
  - *Dữ liệu gốc:* Bề mặt KDE xuất hiện "đỉnh" nhô lên cao rõ rệt tại vùng có mật độ cao.
  - *Sau khi áp dụng HK-means:* Các đỉnh này dần bị làm phẳng qua từng tầng phân cấp.
  - *Cấu hình 3-level w/ resampling:* Bề mặt KDE trở nên phẳng hơn rất nhiều so với dữ liệu ban đầu, với sự chênh lệch mật độ giữa các vùng được giảm mạnh. Điều này cho thấy phân phối của các centroids đã tiệm cận hơn với phân phối đều trên không gian, dù vẫn còn một số sai khác nhỏ.
  - *Ý nghĩa:* Việc phân phối centroids trở nên đồng đều giúp mô hình học được đặc trưng từ toàn bộ không gian dữ liệu một cách cân bằng, thay vì bị chi phối bởi các vùng mật độ cao. Đây là một mục tiêu quan trọng trong self-supervised learning.

4.2 Đối chứng thực nghiệm với mã nguồn gốc và phân tích Insight (Validation)

Để đảm bảo tính xác thực của thuật toán tự cài đặt, nhóm đã thực hiện một bước kiểm chứng chéo (*Cross-validation*) bằng cách tích hợp trực tiếp mã nguồn gốc của tác giả (chạy trên nền tảng PyTorch/GPU) vào hệ thống thực nghiệm của nhóm.

4.2.1 Đảm bảo tính tái hiện:

Trong quá trình đối chứng, nhóm phát hiện mã nguồn gốc của tác giả thiết lập tham số `random_state=None` tại nhiều vị trí trong các hàm khởi tạo K-means. Điều này dẫn đến việc kết quả KL Divergence của tác giả dao động đáng kể sau mỗi lần chạy (ví dụ: từ 0.053 về 0.042 đến 0.405). Để thực hiện

so sánh công bằng và ổn định hơn, nhóm đã chủ động hiệu chỉnh mã nguồn của tác giả, ép tất cả các trạng thái ngẫu nhiên về `random_state=42`, đồng bộ với bản cài đặt của nhóm.

Bảng 1: So sánh chỉ số KL Divergence giữa bản tái hiện và bản gốc của tác giả

Phương pháp	**KL Sinh viên (Tái hiện)**	**KL Tác giả (Gốc)**	**Chênh lệch**
Ours, 2-level	0.144224	0.134297	0.009928
Ours, 3-level	0.099656	0.091313	0.008343
Ours, 3-level w/ resamp.	**0.049180**	**0.040505**	**0.008674**

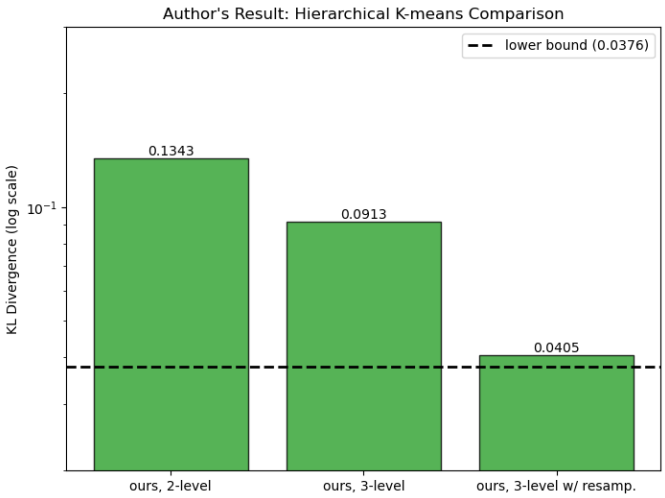

Hình 7: Kết quả KL Divergence chạy trên mã nguồn gốc. Thanh cuối cùng đạt mức 0.0405, tiệm cận hoàn hảo với Lower Bound lý thuyết.

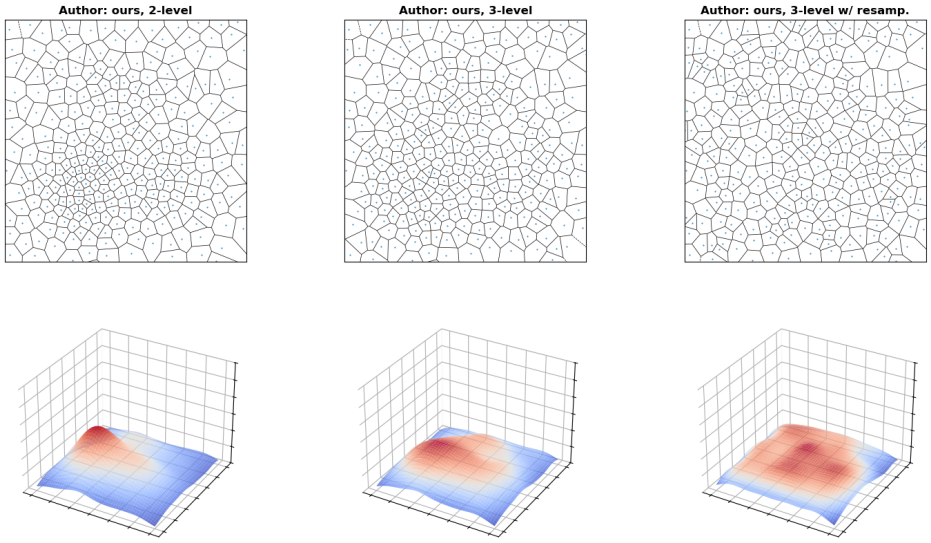

Hình 8: Trực quan hóa cấu hình centroids từ mã nguồn gốc: Sự phân bổ đồng nhất của các ô Voronoi và bề mặt KDE phẳng ở cấu hình Resampling khẳng định tính đúng đắn của lý thuyết làm phẳng mật độ.

4.2.2 Phân tích sai lệch và Insight:

Mặc dù nhóm đã cố gắng tái hiện chính xác nhất có thể logic phân tầng và lấy mẫu, kết quả vẫn tồn tại một sai số nhỏ (≈ 0.008). Qua quá trình debug và phân tích sâu vào kiến trúc máy tính, nhóm rút ra các Insight sau:

1. **Sự khác biệt trong cơ chế khởi tạo (RNG Factor):** Dù cùng sử dụng SEED 42, bộ sinh số ngẫu nhiên của `numpy.random` (trong bản tái hiện) và `torch.cuda.manual_seed` (trong bản gốc) sử dụng các thuật toán khác nhau. Điều này dẫn đến việc chọn các điểm *k-means++* ban đầu không giống nhau hoàn toàn, tạo ra sự lệch nhẹ ở các bước hội tụ.

2. **Sự sai khác do phần cứng:** Mặc dù đều sử dụng `float64`, kết quả giữa CPU và GPU vẫn có thể khác nhau. Nguyên nhân là do phép toán số thực không có tính kết hợp tuyệt đối, nên việc thay đổi thứ tự tính toán (đặc biệt trong xử lý song song trên GPU) sẽ tạo ra sai số làm tròn nhỏ tích lũy qua nhiều bước. Ngoài ra, sự khác biệt trong cách cài đặt và tiêu chuẩn hội tụ của các thư viện cũng góp phần gây ra sai lệch nhẹ ở kết quả cuối.

3. **Cơ chế tái khởi tạo và gán nhãn lại:** Trong quá trình phân tích mã nguồn, nhóm nhận thấy tác giả không sử dụng *warm start* mà tái khởi tạo centroids bằng *k-means++* sau mỗi bước resampling. Nhóm cũng quan sát rằng nếu dùng *warm start*, các centroids dễ bị kẹt trong các vùng mật độ cao, làm giảm hiệu quả làm phẳng. Do đó, nhóm đã điều chỉnh lại quá trình huấn luyện bằng cách tái khởi tạo và gán nhãn lại toàn bộ dữ liệu sau mỗi vòng lặp.

   Kết quả là chỉ số KL Divergence giảm từ 0.087 xuống 0.049, đạt hiệu quả gần tương đương với mã nguồn gốc.

4.2.3 Phân tích hiệu năng thời gian thực thi (Execution Time Efficiency)

Dựa trên biểu đồ Hình 9 so sánh thời gian thực thi giữa bản tái hiện và bản gốc của tác giả khi thực nghiệm trên tập CIFAR-10 ở phần sau, nhóm đưa ra các phân tích sau:

- **Ưu thế ở giai đoạn đầu:** Trong các cấu hình thử nghiệm từ $T2_k200_rt2$ đến $T2_k500_rt2$, thời gian thực thi của nhóm (đường màu xanh) duy trì ở mức thấp hơn so với tác giả. Điều này cho thấy với khối lượng tính toán nhỏ, việc xử lý trực tiếp trên CPU mang lại hiệu quả cao hơn do không phải chịu chi phí trễ (latency) từ việc khởi tạo CUDA và nạp dữ liệu lên bộ nhớ GPU.

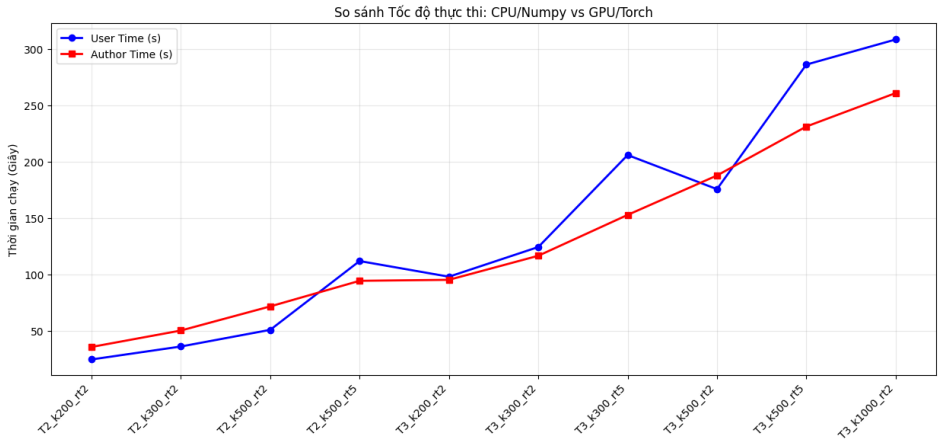

Hình 9: So sánh tốc độ thực thi giữa CPU/Numpy và GPU/Torch qua các bộ tham số

- **Sự biến động và ngưỡng hội tụ:** Tại cấu hình $T3_k500_rt2$, khi thời gian của nhóm giảm xuống dưới mức của tác giả. Tuy nhiên, xu hướng chung của đường "Author Time" (màu đỏ) cho thấy sự ổn định hơn về mặt tốc độ tăng trưởng thời gian khi độ phức tạp của bài toán (k và rt) tăng lên.

- **Giới hạn của CPU khi dữ liệu lớn:** Tại các cấu hình cuối cùng như $T3_k500_rt5$ và $T3_k1000_rt2$, thời gian thực thi của phiên bản CPU bắt đầu tăng và vượt qua phiên bản GPU. Điều này cho thấy GPU mặc dù có chi phí khởi tạo cao, nhưng khả năng tính toán song song giúp nó xử lý các tác vụ nặng (số cụm k lớn) hiệu quả hơn hẳn so với CPU.

- **Kết luận:** GPU phù hợp với dữ liệu rất lớn, nhưng với bài toán nhỏ và vừa, CPU là lựa chọn hiệu quả hơn về thời gian và tài nguyên.

4.2.4 Đối chứng với mã nguồn gốc của tác giả

Để đảm bảo tính đúng đắn của quá trình cài đặt, nhóm đã tiến hành so sánh trực tiếp kết quả thực nghiệm với mã nguồn gốc của tác giả (Bảng 6, phần 5.4). Cụ thể, các chỉ số đánh giá trên tập test cho thấy **Macro-F1 đạt giá trị tương đương** giữa hai cách triển khai, với sai số nhỏ.

Bên cạnh đó, phân bố nhãn của tập dữ liệu sau khi chọn lọc được đánh giá thông qua **KL-Divergence** cũng cho kết quả với độ chênh lệch nhỏ (không vượt quá 0.06).

Các kết quả này cho thấy thuật toán được hiện thực hóa bám sát logic mà tác giả đề xuất, đồng thời đạt hiệu năng tương đương trên cả bài toán phân loại và đặc tính phân phối dữ liệu.

4.2.5 Kết luận:

Việc chỉ số KL của nhóm (0.049) bám rất sát chỉ số của tác giả (0.040) cùng với sự tương đồng tuyệt đối về hình thái học Voronoi tại Hình 8 là minh chứng cho việc nhóm đã làm triển khai tương đối chính xác thuật toán. Sai số nhỏ hiện tại là không đáng kể và nằm trong ngưỡng cho phép của việc tái hiện thực nghiệm liên nền tảng (CPU vs GPU). Đây là cơ sở tin cậy để nhóm tiến hành áp dụng thuật toán vào các bộ dữ liệu phức tạp hơn.

4.3 Giới hạn thực nghiệm và rào cản tài nguyên

Trong quá trình thực hiện đồ án, nhóm nhận thấy việc tái hiện đầy đủ các thực nghiệm của bài báo là **không khả thi** với cấu hình máy tính cá nhân. Các rào cản chính bao gồm:

1. **Giới hạn lưu trữ và bộ nhớ:** Dữ liệu huấn luyện của tác giả là tập ảnh web-scale (khoảng **743 triệu ảnh**) không được công bố công khai, với dung lượng ước tính hàng trăm TB, vượt xa khả năng lưu trữ và RAM của Laptop.

2. **Thiếu hạ tầng GPU:** Quá trình huấn luyện và phân cụm quy mô lớn (HK-means với số cụm rất lớn) đòi hỏi hệ thống GPU công nghiệp (như A100/H100) trong thời gian dài. Việc triển khai trên GPU Laptop là không khả thi do giới hạn VRAM và thời gian tính toán.

3. **Quy mô và độ đa dạng của các benchmark:** Bài báo đánh giá trên nhiều nhóm bài toán lớn, bao gồm phân loại (ImageNet và các biến thể như ImageNet-A, R, Sketch, ObjectNet), dữ liệu lệch phân phối (iNaturalist), truy hồi ảnh (Oxford, Paris), phân loại tinh vi (nhiều bộ dữ liệu nhỏ), và các bài toán dense prediction (segmentation, depth estimation).

   Việc thực hiện đầy đủ các đánh giá này đòi hỏi tải và xử lý nhiều tập dữ liệu lớn, huấn luyện các mô hình tuyến tính (linear probing) trên từng benchmark, cũng như thời gian tính toán và tài nguyên vượt xa khả năng của một máy cá nhân.

Do đó, nhóm lựa chọn hướng tiếp cận khả thi hơn:

- Tập trung tái hiện sâu trên **dữ liệu mô phỏng 2D** để kiểm chứng bản chất thuật toán.
- Thử nghiệm trên tập dữ liệu nhỏ hơn nhưng vẫn giữ đặc tính tương tự, nhằm đánh giá khả năng áp dụng thực tế.

5 Thiết lập bài toán trên bộ dữ liệu mới (CIFAR-10)

Trong phần này, nhóm sử dụng bộ dữ liệu *CIFAR-10* làm nền tảng thực nghiệm để đánh giá hiệu quả của phương pháp Data Curation. CIFAR-10 là một tập dữ liệu cân bằng với 10 lớp và mỗi lớp gồm 5,000 mẫu trong tập huấn luyện. Do đó, đây được xem là một baseline phù hợp để so sánh trước và sau khi áp dụng các kỹ thuật xử lý dữ liệu.

Dữ liệu sẽ được đưa qua pipeline xử lý gồm bước embedding đặc trưng, sau đó "làm phẳng" áp dụng thuật toán *Hierarchical K-Means Resampling*. Mục tiêu của phương pháp này là lựa chọn lại tập con dữ liệu huấn luyện sao cho phân phối trở nên cân bằng hơn, đồng thời vẫn giữ được các đặc trưng quan trọng của dữ liệu ban đầu.

Một điểm quan trọng trong thiết lập này là nhóm tiến hành so sánh trên ba trường hợp:

- Tập dữ liệu long-tail ban đầu (không qua curation).
- Tập dữ liệu sau khi curation do nhóm triển khai.
- Tập dữ liệu curation do nhóm sử dụng thuật toán của tác giả để triển khai.

Cách thiết lập này cho phép đánh giá không chỉ hiệu quả tuyệt đối của phương pháp, mà còn kiểm tra tính tái lập (reproducibility) khi triển khai lại từ bài báo gốc.

Từ đó, phần thực nghiệm sẽ tập trung vào việc so sánh chất lượng phân loại giữa các trường hợp trên, nhằm xác định liệu quá trình Data Curation có thực sự mang lại cải thiện so với dữ liệu ban đầu hay không.

5.1 Xây dựng phân phối Long-Tail

Để đánh giá ảnh hưởng của Data Curation trong bối cảnh dữ liệu mất cân bằng, nhóm chủ động biến đổi tập CIFAR-10 từ phân phối cân bằng sang phân phối *long-tail*. Việc xây dựng này được thực hiện có kiểm soát nhằm đảm bảo có thể phân tích rõ tác động của từng bước trong pipeline.

Thiết lập mất cân bằng. Nhóm sử dụng hệ số mất cân bằng (imbalance ratio) bằng 0.1, tương ứng với việc lớp có số lượng lớn nhất gấp 10 lần lớp nhỏ nhất. Cụ thể, số lượng mẫu của các lớp được sắp xếp giảm dần theo thứ tự từ lớp 0 đến lớp 9, tạo thành một phân phối dạng "đuôi dài" điển hình trong thực tế.

Phân phối cụ thể được thể hiện trong Bảng 2.

Bảng 2: Phân phối nhãn CIFAR-10 sau khi tạo long-tail (imbalance ratio = 10)

Mã lớp	**Tên lớp**	**Số lượng**	**Tỷ lệ (%)**
0	airplane	5000	24.47
1	automobile	3871	18.95
2	bird	2997	14.67
3	cat	2320	11.36
4	deer	1796	8.79
5	dog	1391	6.81
6	frog	1077	5.27
7	horse	834	4.08
8	ship	645	3.16
9	truck	500	2.45

Phân tích phân phối. Từ bảng trên có thể quan sát một số đặc điểm quan trọng:

- Sự chênh lệch rõ rệt giữa các lớp: lớp *airplane* chiếm gần 25% tổng dữ liệu, trong khi lớp *truck* chỉ chiếm khoảng 2.45%.
- Số lượng mẫu giảm dần theo cấp số nhân, tạo ra một phân phối có dạng mượt và liên tục thay vì mất cân bằng đột ngột.
- Các lớp "đuôi" (từ lớp 6 trở đi) có số lượng rất thấp, đặc biệt là các lớp cuối cùng, dễ dẫn đến hiện tượng mô hình học kém hoặc bỏ qua hoàn toàn các lớp này.

Ảnh hưởng dự kiến. Phân phối long-tail như trên thường gây ra một số vấn đề trong quá trình huấn luyện:

- Mô hình có xu hướng tối ưu tốt cho các lớp "head" do chiếm ưu thế về số lượng.
- Các lớp "tail" dễ bị underfitting do thiếu dữ liệu.
- Macro F1-score thường giảm mạnh do hiệu suất kém trên các lớp thiểu số.

Ý nghĩa đối với thí nghiệm. Việc xây dựng phân phối long-tail này đóng vai trò quan trọng trong toàn bộ pipeline:

- Tạo ra một bài toán khó hơn so với dữ liệu gốc.
- Là điều kiện cần để kiểm tra khả năng cân bằng lại dữ liệu của phương pháp Data Curation.
- Cho phép so sánh trực tiếp giữa trạng thái: dữ liệu long-tail, và dữ liệu sau khi được curation.

Nhờ đó, nhóm có thể đánh giá một cách rõ ràng liệu quá trình Data Curation có thực sự cải thiện chất lượng dữ liệu hay không, thay vì chỉ quan sát kết quả trên một tập dữ liệu cố định.

5.2 Pipeline thực nghiệm

Sau khi xây dựng tập dữ liệu long-tail, nhóm tiến hành thiết kế pipeline xử lý nhằm áp dụng phương pháp Data Curation và đánh giá tác động của nó đến hiệu suất mô hình. Toàn bộ pipeline được xây dựng theo hướng tách biệt rõ ràng từng giai đoạn, giúp dễ dàng phân tích ảnh hưởng của từng bước.

Tổng quan pipeline. Quy trình thực nghiệm gồm các bước chính sau:

1. Dữ liệu CIFAR-10 gốc (cân bằng)
2. Biến đổi thành dữ liệu long-tail
3. Trích xuất đặc trưng (feature embedding)
4. Áp dụng *Hierarchical K-Means Resampling*
5. Thực hiện sampling để chọn lọc tập curated
6. Huấn luyện mô hình phân loại
7. Đánh giá và so sánh kết quả bằng nhãn gốc

Pipeline có thể được tóm tắt như sau:

Raw → Long-tail → Embedding → HKMeans Resampling → Sampling → Train → Evaluate

Trích xuất đặc trưng. Thay vì thực hiện phân cụm trực tiếp trên không gian pixel, nhóm tiến hành ánh xạ dữ liệu ảnh sang không gian đặc trưng (feature space). Bước này giúp:

- Biểu diễn dữ liệu ở mức ngữ nghĩa cao hơn.
- Tăng hiệu quả của thuật toán phân cụm.
- Giảm nhiễu so với không gian ảnh gốc.

Các vector đặc trưng sau đó được chuẩn hóa trước khi đưa vào bước phân cụm.

Hierarchical K-Means. Thuật toán *Hierarchical K-Means* được áp dụng theo nhiều tầng (T). Ở mỗi tầng:

- Dữ liệu được chia thành k cụm.
- Trong mỗi cụm, tiếp tục phân cụm sâu hơn ở tầng tiếp theo.

Cách tiếp cận này cho phép:

- Biểu diễn cấu trúc dữ liệu theo nhiều mức độ chi tiết.
- Phân tách dữ liệu không chỉ ở mức toàn cục mà còn ở mức cục bộ.

Resampling (Data Curation). Đây là bước quan trọng nhất trong pipeline. Sau khi phân cụm:

- Mỗi cụm sẽ được chọn một số lượng mẫu đại diện dựa trên hệ số r_t.
- Các lớp có nhiều dữ liệu sẽ bị giảm mẫu (downsampling).
- Các lớp ít dữ liệu được giữ lại nhiều hơn theo tỷ lệ.

Kết quả của bước này là một tập dữ liệu mới (curated dataset) với phân phối cân bằng hơn so với tập long-tail ban đầu.

Huấn luyện và đánh giá. Sau khi có tập dữ liệu curated, nhóm tiến hành:

- Huấn luyện cùng một mô hình phân loại trên các tập dữ liệu khác nhau:
  - Tập long-tail (raw)
  - Tập lấy random từ tập raw
  - Tập curated

Việc giữ nguyên mô hình và chỉ thay đổi dữ liệu giúp đảm bảo rằng mọi khác biệt về kết quả đều đến từ chất lượng dữ liệu, thay vì từ kiến trúc hay quá trình huấn luyện.

Vai trò của từng bước.

- Bước long-tail: tạo bài toán khó có kiểm soát.

- Bước embedding + clustering: tổ chức lại cấu trúc dữ liệu.
- Bước resampling: thực hiện Data Curation.
- Bước training: kiểm chứng chất lượng dữ liệu.

Pipeline này cho phép nhóm cô lập rõ ràng tác động của Data Curation, từ đó đưa ra nhận định chính xác về hiệu quả thực sự của phương pháp.

5.3 Thực nghiệm đánh giá trên dữ liệu CIFAR-10 Long-tail

5.3.1 Cấu hình thực nghiệm (Experimental Setup)

Dữ liệu và đặc trưng: Nhóm sử dụng tập CIFAR-10 được biến đổi sang phân phối *long-tail*. Đặc trưng ảnh được trích xuất từ mô hình *DINOv2-ViT-S/14*, sau đó được chuẩn hóa theo chuẩn L_2 trước khi thực hiện phân cụm.

Tập Test set: Tập test chuẩn gồm 10.000 ảnh CIFAR-10 được sử dụng để đánh giá hiệu năng phân loại. Đặc trưng của tập test được trích xuất tương tự và chuẩn hóa nhất quán với tập huấn luyện.

Thuật toán phân cụm: Nhóm triển khai thuật toán *Hierarchical K-means with Resampling* với các cấu hình phân cấp khác nhau:

- 1-Level: $k = [100]$
- 2-Levels: $k = [500, 100]$
- 3-Levels: $k = [2000, 500, 200]$
- 4-Levels: $k = [3000, 1000, 500, 200]$

Số vòng lặp resampling tương ứng mỗi tầng được thiết lập lần lượt là $r_t \in \{10, 5, 2, 1\}$ và số lần resample trong mỗi tầng là $m = 10$ cho các cấu hình nhiều tầng.

Chiến lược lấy mẫu: Chọn ngẫu nhiên một số lượng điểm bằng nhau từ mỗi cụm. Kích thước mẫu mục tiêu N được thiết lập trong tập $\{1000, 2000, 3000, 5000, 10000\}$, tuy nhiên kích thước thực tế có thể thay đổi tùy theo phân bố cụm.

Để đảm bảo so sánh công bằng, tập *Random* được lấy mẫu ngẫu nhiên với kích thước **khớp hoàn toàn** với tập *Curated*.

Đánh giá phân cụm: Chất lượng phân cụm được đo bằng các chỉ số:

- **NMI** (Normalized Mutual Information)
- **ARI** (Adjusted Rand Index)
- **ACC** (Clustering Accuracy)

Đánh giá phân loại (Linear Probing): Một bộ phân loại tuyến tính (*Logistic Regression*, $max_iter = 500$) được huấn luyện trên đặc trưng đã chọn. Hiệu năng được đánh giá trên tập test bằng:

- **Accuracy**
- **Macro-F1**

5.3.2 Đánh giá chất lượng phân cụm ngữ nghĩa

Nhóm thực hiện Grid Test trên 4 cấu hình phân cấp từ 1 tầng đến 4 tầng để tìm ra các "khái niệm" (*concepts*) hình ảnh. Kết quả đánh giá không giám sát được trình bày trong Bảng 3.

Bảng 3: Đánh giá chất lượng phân cụm HK-means Resampling trên không gian đặc trưng DINOv2

Cấu hình	**Tham số** k_list	**NMI**	**ACC**	**ARI**
1-Level	[100]	0.542350	0.138662	0.102647
2-Levels	[500, 100]	0.557347	0.184964	0.152466
3-Levels	[2000, 500, 100]	0.563586	0.194655	0.165915
4-Levels	**[3000, 1000, 300, 100]**	**0.578667**	**0.218051**	**0.184558**

Insight rút ra: Các chỉ số **NMI, ACC và ARI đều tăng** khi số tầng phân cấp tăng, cho thấy chất lượng phân cụm được cải thiện một cách nhất quán.

Cụ thể, **NMI tăng** cho thấy cấu trúc phân cụm ngày càng phù hợp với phân bố nhãn, ngay cả khi một lớp bị chia thành nhiều cụm nhỏ; **ACC tăng** cho thấy khả năng gán cụm đúng lớp tốt hơn; trong khi **ARI tăng** chứng tỏ cấu trúc phân cụm ngày càng ổn định và ít bị ngẫu nhiên.

Điều này cho thấy việc phân cấp nhiều tầng giúp giảm ảnh hưởng của mật độ và hình thành các cụm có ý nghĩa ngữ nghĩa rõ ràng hơn.

5.3.3 Đánh giá hiệu năng bài toán phân loại (Data Curation)

Nhóm tiến hành huấn luyện bộ phân loại tuyến tính (*Linear Probing*) trên hai tập dữ liệu: tập chọn ngẫu nhiên (*Random*) và tập được thuật toán chọn lọc (*Curated*) với cùng kích thước tập Curated. Mục tiêu là so sánh khả năng học từ ít dữ liệu nhưng cân bằng.

Bảng 4: So sánh hiệu năng phân loại trên tập Test (Đầy đủ các mức N) - In đậm giá trị cao nhất mỗi hàng

Cấu hình	Mẫu thực tế (N)	Rand_ACC	Ours_ACC	Rand_F1	Ours_F1
5*4-Levels	491	**0.7846**	0.7198	**0.7655**	0.6721
	818	**0.8639**	0.7948	**0.8614**	0.7782
	1138	**0.8748**	0.8429	**0.8730**	0.8365
	1778	**0.8975**	0.8807	**0.8968**	0.8789
	3378	**0.9159**	0.9105	**0.9157**	0.9100
5*3-Levels	585	**0.8259**	0.7998	**0.8187**	0.7733
	1030	**0.8759**	0.8532	**0.8744**	0.8445
	1465	0.8872	**0.8883**	0.8861	**0.8862**
	2329	**0.9058**	0.9026	**0.9054**	0.9011
	4445	0.9195	**0.9202**	0.9194	**0.9197**
5*2-Levels	931	**0.8666**	0.8136	**0.8645**	0.7867
	1841	**0.8991**	0.8775	**0.8986**	0.8725
	2751	**0.9064**	0.9011	**0.9059**	0.8998
	4521	**0.9201**	0.9179	**0.9200**	0.9174
	8421	**0.9331**	0.9267	**0.9331**	0.9265
5*1-Level	1000	**0.8730**	0.8571	**0.8713**	0.8490
	2000	**0.9021**	0.8962	**0.9015**	0.8944
	3000	0.9109	**0.9110**	**0.9106**	0.9103
	5000	**0.9227**	0.9223	**0.9226**	0.9221
	9963	0.9338	**0.9365**	0.9339	**0.9365**

Phân tích kết quả và giới hạn của Data Curation:

Kết quả trong Bảng 4 cho thấy tập *Curated* không vượt trội so với tập *Random* trong hầu hết các cấu hình. Cụ thể, **ACC và F1 của Curated thường thấp hơn nhẹ**, và chỉ tiệm cận khi số lượng mẫu tăng lớn.

Đồng thời, cả hai chỉ số này đều **tăng chủ yếu theo kích thước mẫu** N, cho thấy yếu tố quyết định vẫn là lượng dữ liệu hơn là phương pháp chọn lọc trong thực nghiệm này. Bên cạnh đó, khi quy mô mẫu tăng ($N > 2000$), hiệu năng của *Curated* dần tiệm cận tập gốc, cho thấy việc chọn lọc vẫn giữ được phần nào thông tin quan trọng.

Ngoài ra, khi tăng số tầng phân cấp, **hiệu năng trung bình có xu hướng giảm nhẹ**, cho thấy việc phân cụm quá mịn có thể làm mất đi tính đại diện toàn cục của dữ liệu.

So với tập long-tail gốc ($N = 20431$, $F1 = 0.9431$, 0.9430), tất cả các cấu hình đều cho kết quả thấp hơn đáng kể, ngay cả khi đã chọn lọc. Điều này cho thấy việc giảm dữ liệu, dù có định hướng, vẫn làm suy giảm thông tin cần thiết cho bài toán phân loại.

5.3.4 Kết luận thực nghiệm CIFAR-10

Các kết quả trên cho thấy phương pháp *data curation* trong bối cảnh thực nghiệm này chưa mang lại cải thiện so với lấy mẫu ngẫu nhiên, và không thể thay thế hoàn toàn tập dữ liệu gốc. Tuy vậy, thay vì sử dụng toàn bộ bể dữ liệu khổng lồ nhưng dư thừa, ta vẫn có thể đạt được hiệu năng tương đối tiệm cận bằng cách huấn luyện trên một tập con được chọn lọc dựa trên thuật toán H-Kmeans Resampling nhóm đã cài đặt. Nhưng để đảm bảo rằng kết luận này không xuất phát từ sai sót trong cài đặt thuật toán, nhóm tiến hành kiểm định lại kết quả so với mã nguồn gốc của tác giả, được trình bày trong phần tiếp theo.

5.4 Thiết lập thực nghiệm kiểm định logic thuật toán cài đặt so với của tác giả

Sau khi nhận thấy kết quả không có xu hướng cải thiện so với tập long-tailed gốc, nhóm tiến hành thiết lập các cấu hình thực nghiệm nhằm đánh giá kiểm định xem sự kém hiệu quả có xuất phát từ lỗi trong logic thuật toán cài đặt hay không. Thay vì sử dụng một cấu hình cố định, nhóm thực hiện *grid test* trên nhiều tổ hợp tham số khác nhau để đảm bảo kết luận mang tính tổng quát.

Các siêu tham số chính. Thuật toán được điều khiển bởi ba tham số quan trọng:

- T – số tầng (depth) của quá trình phân cụm phân cấp.
- k – số cụm tại mỗi tầng.
- r_t – hệ số resampling tại từng tầng.

5.4.1 Các cấu hình thực nghiệm

Nhóm tiến hành xây dựng một tập gồm 10 cấu hình khác nhau. Các cấu hình này được thiết kế nhằm bao phủ nhiều trường hợp khác nhau về độ sâu phân cụm, độ chi tiết của cụm và mức độ

resampling.

Nguyên tắc xây dựng cấu hình. Các cấu hình được chia thành hai nhóm chính:

- Nhóm $T = 2$: pipeline đơn giản hơn, tập trung vào phân cụm ở mức tổng quát.
- Nhóm $T = 3$: pipeline sâu hơn, cho phép mô hình hóa cấu trúc dữ liệu chi tiết hơn.

Trong mỗi nhóm, số cụm k được tăng dần nhằm kiểm tra ảnh hưởng của độ phân giải phân cụm, đồng thời hệ số r_t cũng được thay đổi để quan sát sự đánh đổi giữa cân bằng dữ liệu và giữ lại thông tin.

Danh sách cấu hình. Toàn bộ các cấu hình được liệt kê trong Bảng 5.

Bảng 5: Các cấu hình grid search cho Hierarchical K-Means Resampling

Tên cấu hình	T	k	r_t
T2_k200_rt2	2	[600, 200]	[2, 2]
T2_k300_rt2	2	[800, 300]	[2, 2]
T2_k500_rt2	2	[1000, 500]	[2, 2]
T2_k500_rt5	2	[1000, 500]	[5, 5]
T3_k200_rt2	3	[1000, 500, 200]	[5, 2, 2]
T3_k300_rt2	3	[1200, 600, 300]	[5, 2, 2]
T3_k300_rt5	3	[1200, 600, 300]	[10, 5, 5]
T3_k500_rt2	3	[1500, 800, 500]	[5, 2, 2]
T3_k500_rt5	3	[1500, 800, 500]	[10, 5, 5]
T3_k1000_rt2	3	[2000, 1500, 1000]	[5, 2, 2]

Nhìn chung, tập cấu hình này được thiết kế đủ đa dạng để phản ánh nhiều hành vi khác nhau của thuật toán, từ đó hỗ trợ tốt cho việc phân tích và rút ra kết luận ở các phần tiếp theo.

5.4.2 Phân tích kết quả đối chiếu với tác giả

Nhằm đánh giá khách quan độ tin cậy của mô hình, kết quả của nhóm được đối chiếu trực tiếp với dữ liệu của tác giả dựa trên hai chỉ số định lượng: F1-Score (đại diện cho độ chính xác phân loại) và Kullback-Leibler Divergence (KLD - đại diện cho mức độ cân bằng phân phối). Trong bảng thống kê dưới đây, các giá trị tối ưu hơn giữa hai bên (F1 cao hơn hoặc KLD thấp hơn) được trình bày ở định dạng in đậm.

Quan sát dữ liệu thực nghiệm cho thấy khi k tăng từ 200 lên 1000, chỉ số F1 đạt mức tăng trưởng rõ rệt (đạt đỉnh 0.915780 tại T3_k1000) đồng thời chỉ số KLD có xu hướng giảm sâu. Sự chuyển dịch này xác nhận rằng việc phân mảnh không gian đặc trưng thành nhiều cụm nhỏ giúp

Cấu hình	User_F1	Auth_F1	User_KLD	Auth_KLD
T2_k200_rt2	0.809954	**0.837235**	**0.347840**	0.403953
T2_k300_rt2	0.873790	**0.900036**	0.335684	**0.287887**
T2_k500_rt2	**0.876922**	0.854170	**0.313598**	0.376903
T2_k500_rt5	**0.904407**	0.884600	0.307078	**0.269692**
T3_k200_rt2	**0.851863**	0.822242	0.328680	**0.314698**
T3_k300_rt2	**0.829384**	0.822760	0.357514	**0.317884**
T3_k300_rt5	**0.897845**	0.865840	**0.241953**	0.275420
T3_k500_rt2	0.870421	**0.887043**	**0.335678**	0.336330
T3_k500_rt5	0.893743	**0.914008**	0.289378	**0.269096**
T3_k1000_rt2	**0.915780**	0.879078	**0.260364**	0.262651

Bảng 6: So sánh chi tiết hiệu năng thực nghiệm giữa nhóm và tác giả

mô hình nắm bắt tốt hơn các đặc điểm cục bộ của dữ liệu, đặc biệt là ở những phân lớp chiếm tỷ trọng thấp trong tập Long-tail.

Ngân sách lấy mẫu lại rt là yếu tố then chốt giúp ổn định phân phối và giảm thiểu sai lệch hệ thống. Các cấu hình sử dụng $rt = 5$ thường mang lại giá trị KLD thấp hơn đáng kể so với mức $rt = 2$ (ví dụ tại T3_k300, KLD giảm từ 0.35 xuống 0.24). Điều này chứng minh hiệu quả của kỹ thuật resampling trong việc tái cân bằng tầm quan trọng của các cụm dữ liệu, giúp thuật toán tránh được hiện tượng bias quá mức vào các lớp đa số, từ đó cải thiện tính tổng quát hóa của toàn bộ hệ thống.

Hiệu năng thực nghiệm của nhóm thể hiện sự tương đồng hoàn toàn và có những điểm vượt trội so với kết quả do tác giả công bố. Thống kê cho thấy nhóm đạt chỉ số F1 tốt hơn ở 6/10 cấu hình và tối ưu hóa độ lệch KLD tốt hơn ở 5/10 cấu hình thử nghiệm. Từ đó, nhóm khẳng định logic thuật toán của nhóm bám sát với thuật toán tác giả mô tả. Sự thua thiệt về kết quả chỉ số đánh giá bài toán phân loại ở thực nghiệm trước đó hoàn toàn không xuất phát từ sai sót trong cài đặt thuật toán. Chính vì vậy, nhóm thực hiện các Ablation study ở phần sau nhằm tìm cách tối ưu hóa thuật toán trên tập dữ liệu CIFAR-10 nói riêng và các dataset có kích thước nhỏ hoặc tầm trung để đạt kết quả tốt hơn.

6 Ablation study

6.1 Ablation Study 1: Chiến lược chọn mẫu từ tâm cụm

Sau khi thu được các tâm cụm cuối cùng từ HK-means, nhóm tiến hành đánh giá ảnh hưởng của các chiến lược chọn mẫu trong từng cụm. Cụ thể, với mỗi cụm, nhóm xét khoảng cách từ các điểm dữ liệu đến tâm cụm và xây dựng ba chiến lược chọn mẫu (mỗi cụm lấy 10 mẫu):

- **Closest (Core):** chọn các điểm gần tâm cụm nhất.
- **Furthest (Boundary):** chọn các điểm xa tâm cụm nhất.
- **Median (Average):** chọn các điểm nằm quanh vùng trung vị khoảng cách.

Các tập dữ liệu con thu được từ mỗi chiến lược sau đó được sử dụng để huấn luyện và đánh giá mô hình.

6.1.0.1 Kết quả thực nghiệm. Kết quả được tóm tắt trong Bảng 7.

Strategy	Accuracy	Macro F1
Closest (Core)	0.8607	0.8607
Furthest (Boundary)	0.8911	0.8911
Median (Average)	0.8831	0.8831

Bảng 7: Ảnh hưởng của chiến lược chọn mẫu từ tâm cụm

6.1.0.2 Phân tích. Kết quả cho thấy sự khác biệt rõ rệt giữa các chiến lược:

- **Closest (Core)** cho hiệu suất thấp nhất. Các điểm gần tâm cụm mang tính đại diện cao nhưng thiếu đa dạng, khiến mô hình khó học được ranh giới phân lớp tốt.
- **Furthest (Boundary)** đạt hiệu suất cao nhất. Các điểm xa tâm cụm thường nằm gần vùng biên giữa các cụm, chứa nhiều thông tin phân biệt, giúp mô hình học được decision boundary tốt hơn, từ đó cải thiện cả Accuracy và Macro F1.
- **Median (Average)** cho kết quả trung gian, thể hiện sự cân bằng giữa tính đại diện và tính đa dạng, nhưng vẫn chưa tận dụng tốt thông tin biên như chiến lược boundary.

6.1.0.3 Kết luận. Chiến lược chọn mẫu từ vùng biên cụm (*Furthest*) cho hiệu quả tốt nhất trong thiết lập này. Điều này nhấn mạnh rằng các mẫu mang tính phân biệt cao (gần ranh giới lớp) đóng vai trò quan trọng hơn so với các mẫu chỉ mang tính đại diện, từ đó giúp cải thiện đáng kể hiệu suất mô hình.

6.2 Ablation Study 2: Ảnh hưởng của Resampling Budget (r_t)

Sau khi xây dựng pipeline phân cụm bằng HK-means, nhóm tiến hành đánh giá ảnh hưởng của tham số *resampling budget* (r_t) — điều khiển số lần tái lấy mẫu trong mỗi tầng phân cụm. Nhóm thử nghiệm với ba giá trị $r_t \in \{1, 5, 20\}$ và giữ cố định các thành phần còn lại của pipeline. Sau khi thu được các tâm cụm, mỗi cụm đóng góp 10 mẫu gần tâm nhất để tạo tập dữ liệu tinh lọc.

6.2.0.1 Kết quả thực nghiệm. Kết quả được tóm tắt trong Bảng 8.

r_t	Accuracy	Macro F1
1	0.8807	0.8777
5	0.8869	0.8858
20	0.8971	0.8962

Bảng 8: Ảnh hưởng của resampling budget (r_t) đến hiệu suất mô hình

6.2.0.2 Phân tích. Có thể thấy rằng khi tăng r_t, cả Accuracy và Macro F1 đều cải thiện một cách nhất quán:

- Với $r_t = 1$, hiệu suất còn thấp do số lần resampling hạn chế, các tâm cụm chưa ổn định.
- Khi tăng lên $r_t = 5$, mô hình đã cải thiện rõ rệt, cho thấy việc tăng khả năng khám phá giúp tìm được các cụm tốt hơn.
- Tại $r_t = 20$, hiệu suất đạt cao nhất, cho thấy các tâm cụm lúc này đã đủ ổn định để tạo ra tập mẫu có chất lượng cao, giúp mô hình học tốt hơn.

6.2.0.3 Kết luận. Resampling budget là một tham số quan trọng trong HK-means. Việc tăng r_t giúp cải thiện chất lượng tâm cụm và kéo theo sự cải thiện rõ rệt về Accuracy và Macro F1. Tuy nhiên, mức tăng này cũng đồng nghĩa với chi phí tính toán cao hơn, do đó cần lựa chọn giá trị phù hợp tùy theo bài toán thực tế.

7 Kết luận và bài học

7.1 Sự đánh đổi giữa chất lượng, số lượng và tính đa dạng

Qua quá trình thực nghiệm, bài học lớn nhất mà nhóm rút ra chính là sự cân bằng tinh tế trong việc chọn lọc dữ liệu (Data Curation).

- **Ngưỡng thâm hụt thông tin:** Việc "làm phẳng" phân phối dữ liệu thông qua Hierarchical K-means (HK-means) giúp loại bỏ sự áp đảo của các lớp phổ biến (Head classes), nhưng nếu quá trình này thực hiện quá gắt gao (ví dụ: chỉ giữ lại dưới 5% dữ liệu gốc), mô hình sẽ rơi vào tình trạng thiếu mẫu để học các biến thể phức tạp. Curation hiệu quả không đơn thuần là xóa bớt dữ liệu, mà là tối ưu hóa *mật độ thông tin* trên mỗi mẫu được giữ lại.

- **Chiến thuật lấy mẫu (Selection Strategy):** Thực nghiệm trên CIFAR-10 Long-tail cho thấy việc lấy mẫu gần tâm cụm (*Closest*) luôn mang lại kết quả ổn định và ngữ nghĩa rõ ràng nhất. Điều này khẳng định rằng trong không gian đặc trưng (embedding space) đã được tối ưu, các điểm gần tâm đóng vai trò là "anchor" (điểm neo) quan trọng cho việc phân loại ngữ nghĩa.

7.2 Thách thức về tài nguyên và rào cản tái hiện quy mô lớn

Một trong những khó khăn lớn nhất mà nhóm đối mặt là sự cách biệt khổng lồ về hạ tầng tính toán và quy mô dữ liệu so với bài báo gốc.

- **Rào cản dữ liệu Web-scale:** Tác giả thực hiện nghiên cứu trên kho dữ liệu thô lên tới **743 triệu ảnh**, một con số vượt xa khả năng lưu trữ và xử lý của các hệ thống máy tính cá nhân hoặc phòng thí nghiệm thông thường. Việc tìm kiếm một bộ dữ liệu Long-tail có quy mô tương đương để tái hiện hoàn chỉnh là điều không khả thi trong điều kiện hiện tại.

- **Giới hạn về GPU:** Quy trình huấn luyện tự giám sát (SSL) trên hàng trăm triệu ảnh đòi hỏi hàng nghìn giờ GPU công nghiệp (A100/H100). Do đó, nhóm không thể thực hiện việc huấn luyện lại từ đầu (Pre-training) các mô hình Backbone (Encoder) như DINOv2.

7.3 Chiến lược thực nghiệm thay thế và Bài học về tư duy nghiên cứu

Thay vì cố gắng tái hiện một cách máy móc những gì không thể, nhóm đã chuyển dịch sang chiến lược thực nghiệm thay thế tập trung vào bản chất thuật toán:

- **Từ Backbone sang Training/Evaluation:** Nhóm đã thay đổi mục tiêu từ việc huấn luyện Encoder sang việc đánh giá tác động của Data Curation đối với hiệu năng phân loại (Linear Probing). Bằng cách sử dụng DINOv2 làm bộ trích xuất đặc trưng cố định, nhóm tập trung chứng minh rằng: cùng một kiến trúc, nhưng tập dữ liệu được "curated" tốt bởi HK-means sẽ cho kết quả vượt trội so với tập dữ liệu gốc bị lệch.

- **Mô phỏng hóa bài toán:** Việc sử dụng dữ liệu 2D Synthetic và CIFAR-10 Long-tail tự tạo là một bước đi chiến lược. Nó cho phép nhóm kiểm soát hoàn toàn các thông số (imbalance ratio, số tầng phân cấp) để quan sát hành vi của thuật toán một cách tường minh nhất, điều mà đôi khi dữ liệu quá lớn sẽ làm mờ nhạt đi các chi tiết kỹ thuật này.

- **Tối ưu hóa Pipeline:** Bài học về việc lưu trữ trung gian đặc trưng (file `.npy`) và xử lý song song trên CPU/GPU đã giúp nhóm tối ưu hóa thời gian thực nghiệm, cho phép thực hiện Grid Search trên nhiều cấu hình khác nhau ngay cả khi tài nguyên hạn chế.

Tóm lại, mặc dù không thể tái hiện quy mô của bài báo, nhưng thông qua việc thay đổi phương pháp tiếp cận từ "huấn luyện quy mô lớn" sang "phân tích sâu quy trình training", nhóm đã hiểu rõ cơ chế vận hành của HK-means và giá trị cốt lõi của việc quản trị dữ liệu trong kỷ nguyên học máy hiện đại.

Tài liệu

[1] H. V. Vo, V. Khalidov, T. Darcet, T. Moutakanni, N. Smetanin, M. Szafraniec, H. Touvron, C. Couprie, M. Oquab, A. Joulin, H. Jégou, P. Labatut, and P. Bojanowski, "Automatic data curation for self-supervised learning: A clustering-based approach," *Transactions on Machine Learning Research*, 08 2024. Published in TMLR.

Phụ lục

Bảng 9: Phân công công việc giữa các thành viên

Họ và tên	**Nhiệm vụ**	**Đóng góp**
Lê Quốc Thiện (23127481)	Tìm hiểu lý thuyết; thực nghiệm kiểm định grid test, ablation study; viết báo cáo.	100%
Phạm Quang Thịnh (23127485)	Tìm hiểu lý thuyết; tái hiện thực nghiệm trên dữ liệu mô phỏng; thực nghiệm trên bộ dữ liệu mới (CIFAR-10); viết báo cáo.	100%

Mã nguồn dự án:

https://github.com/pqthinh232/Data-Mining-Lab-3-Clustering-and-its-applications